



**UNIVERSITÀ TELEMATICA INTERNAZIONALE  
UNINETTUNO**

**FACOLTÀ DI INGEGNERIA**

Corso di Laurea Triennale in  
**Ingegneria Informatica**

**ELABORATO FINALE**

in  
Sistemi Informativi e Basi di Dati

**Modelli di Apprendimento Automatico  
per il Monitoraggio Cardiaco e Motorio  
in Percorsi Riabilitativi**

**RELATORE:**

Prof. Mazzei Mauro

**CANDIDATO:**

Guido Giovanni Martini

**ANNO ACCADEMICO 2025/2026**

*A Cristian e Sladana,  
per essermi stati accanto  
in ogni momento di questo percorso.*

*Desidero esprimere la mia sincera gratitudine al Professor Mauro Mazzei per la guida, la disponibilità e i preziosi suggerimenti forniti durante lo sviluppo di questo lavoro. Le sue indicazioni metodologiche e scientifiche hanno contribuito in modo determinante all'impostazione e allo sviluppo della ricerca.*

*Ringrazio i docenti del Corso di Laurea per la formazione ricevuta e per le competenze teoriche e pratiche trasmesse, che hanno costituito una base fondamentale per lo sviluppo di questo elaborato.*

*Un ringraziamento speciale va a mia moglie Sladana e a mio figlio Cristian, per la pazienza, il sostegno e la vicinanza dimostrati durante tutto questo percorso. Il loro affetto e la loro comprensione nei momenti più impegnativi hanno rappresentato una motivazione fondamentale per il raggiungimento di questo traguardo.*

*Desidero inoltre ringraziare gli amici e colleghi della «Banda degli Onesti», in particolare Giorgio, Danilo, Christian, Martina, Dario e Diego. Con loro ho condiviso lezioni, progetti, esami, momenti di confronto e molte delle sfide affrontate durante questo percorso universitario. La loro amicizia e i numerosi momenti trascorsi insieme hanno reso questi anni più stimolanti, piacevoli e ricchi di significato. Un ringraziamento particolare va a Giorgio, con cui la collaborazione è andata oltre lo studio: la sua disponibilità, la condivisione delle difficoltà quotidiane e l'amicizia costruita in questi anni sono qualcosa che porterò con me ben oltre l'università.*

*Ringrazio infine tutti coloro che, direttamente o indirettamente, hanno contribuito al completamento di questo elaborato.*

*Guido Giovanni Martini  
Roma, luglio 2026*

# Indice

|                                                                            |           |
|----------------------------------------------------------------------------|-----------|
| <b>Sommario .....</b>                                                      | <b>IV</b> |
| <b>1 Introduzione .....</b>                                                | <b>1</b>  |
| 1.1 Contesto e Motivazione .....                                           | 1         |
| 1.1.1 Wearable Computing e IoT Medicae .....                               | 2         |
| 1.1.2 Variabilità della Frequenza Cardiaca e Segnali Accelerometrici ..... | 2         |
| 1.2 Obiettivi del Progetto .....                                           | 3         |
| 1.3 Contributo Originale .....                                             | 4         |
| 1.4 Struttura dell'Elaborato .....                                         | 5         |
| <b>2 Background Teorico .....</b>                                          | <b>7</b>  |
| 2.1 Variabilità della Frequenza Cardiaca .....                             | 7         |
| 2.1.1 Definizione e Rilevanza Clinica .....                                | 7         |
| 2.1.2 Algoritmo Pan-Tompkins .....                                         | 8         |
| 2.1.3 Misure Temporalì dell'HRV .....                                      | 8         |
| 2.1.4 Misure Frequenziali dell'HRV .....                                   | 10        |
| 2.1.5 Misure Geometriche e Non-Lineari dell'HRV .....                      | 10        |
| 2.2 Segnale Accelerometrico .....                                          | 12        |
| 2.2.1 Principio di Funzionamento dei Sensori MEMS .....                    | 12        |
| 2.2.2 Estrazione delle Feature dal Segnale Accelerometrico .....           | 13        |
| 2.2.3 Ipotesi sulla Relazione ACC-HRV .....                                | 15        |
| 2.3 Signal Quality Index .....                                             | 15        |
| 2.3.1 Artefatti nei Segnali Fisiologici Indossabili .....                  | 15        |
| 2.3.2 Metriche del Signal Quality Index .....                              | 16        |
| 2.4 Machine Learning per Segnali Fisiologici .....                         | 16        |
| 2.4.1 Approccio a Finestre Temporalì Scorrevoli .....                      | 16        |
| 2.4.2 Modelli di Classificazione .....                                     | 17        |
| 2.4.3 SMOTE e Bilanciamento delle Classi .....                             | 18        |
| 2.4.4 Metriche di Valutazione .....                                        | 19        |
| 2.4.5 Iperparametri e GridSearchCV .....                                   | 19        |
| 2.4.6 Validazione Incrociata e Prevenzione del Data Leakage .....          | 20        |
| <b>3 Dataset e Metodi .....</b>                                            | <b>21</b> |
| 3.1 Descrizione del Dataset .....                                          | 21        |
| 3.2 Pipeline di Pre-elaborazione .....                                     | 21        |
| 3.2.1 Pre-elaborazione ECG .....                                           | 21        |
| 3.2.2 Pre-elaborazione Accelerometro .....                                 | 22        |
| 3.2.3 Segmentazione in Finestre Temporalì .....                            | 22        |
| 3.2.4 Signal Quality Index (SQI) .....                                     | 22        |
| 3.3 Estrazione delle Feature .....                                         | 23        |

|          |                                                                   |           |
|----------|-------------------------------------------------------------------|-----------|
| 3.3.1    | Feature HRV (ECG)                                                 | 23        |
| 3.3.2    | Feature Accelerometriche                                          | 24        |
| 3.3.3    | Feature Cliniche (solo OBJ3)                                      | 24        |
| 3.4      | Classificatore ECG Rule-Based (Scenario B)                        | 24        |
| 3.5      | Configurazione degli Esperimenti                                  | 24        |
| 3.5.1    | Modelli di Classificazione                                        | 24        |
| 3.5.2    | Strategia di Validazione                                          | 25        |
| 3.5.3    | Metriche di Valutazione                                           | 25        |
| 3.6      | Architettura del Sistema Wearable                                 | 26        |
| 3.6.1    | Livello Edge (dispositivo indossabile)                            | 26        |
| 3.6.2    | Livello Cloud                                                     | 26        |
| <b>4</b> | <b>Analisi della Correlazione ACC ↔ HRV</b>                       | <b>28</b> |
| 4.1      | Metodologia Statistica                                            | 28        |
| 4.1.1    | Correlazione di Pearson                                           | 28        |
| 4.1.2    | Regressione Lineare Semplice (OLS)                                | 28        |
| 4.1.3    | Correlazione di Spearman                                          | 28        |
| 4.2      | Risultati delle Correlazioni                                      | 29        |
| 4.2.1    | Top Feature a livello globale                                     | 29        |
| 4.2.2    | Analisi per Tipo di Attività                                      | 30        |
| 4.2.3    | Visualizzazioni                                                   | 30        |
| 4.3      | Interpretazione Clinica                                           | 32        |
| <b>5</b> | <b>Classificazione Automatica</b>                                 | <b>33</b> |
| 5.1      | OBJ1 — Tipo di Attività Motoria (5 Classi)                        | 33        |
| 5.1.1    | Risultati                                                         | 34        |
| 5.1.2    | Confronto dei Modelli                                             | 34        |
| 5.2      | OBJ2 — Distinzione REST vs ACTIVITY                               | 35        |
| 5.2.1    | Risultati                                                         | 35        |
| 5.3      | OBJ3 — Stima dello Stato Clinico NYHA                             | 36        |
| 5.3.1    | Configurazione Sperimentale                                       | 36        |
| 5.3.2    | Risultati e Interpretazione                                       | 36        |
| 5.3.3    | Confronto con la Letteratura                                      | 37        |
| 5.4      | Analisi della Feature Importance                                  | 38        |
| 5.5      | Confronto Sintetico dei Modelli                                   | 41        |
| 5.6      | Limiti Sperimentali                                               | 41        |
| <b>6</b> | <b>Conclusioni e Sviluppi Futuri</b>                              | <b>43</b> |
| 6.1      | Sintesi dei Risultati                                             | 43        |
| 6.2      | Implicazioni Cliniche                                             | 44        |
| 6.3      | Limiti del Lavoro                                                 | 44        |
| 6.4      | Sviluppi Futuri                                                   | 45        |
| 6.5      | Validazione della Pipeline su una Seconda Coorte: Dataset SCG-RHC | 46        |

|                                                  |           |
|--------------------------------------------------|-----------|
| 6.5.1 Obiettivo e Protocollo Sperimentale .....  | 46        |
| 6.5.2 Risultati .....                            | 47        |
| 6.5.3 Discussione .....                          | 47        |
| 6.6 Osservazioni Conclusive .....                | 48        |
| <b>Appendice A — Frammenti di Codice .....</b>   | <b>49</b> |
| Pre-elaborazione ECG e Rilevamento R-peaks ..... | 49        |
| Signal Quality Index (SQI) .....                 | 50        |
| Estrazione Feature HRV .....                     | 50        |
| Pipeline di Classificazione con GroupKFold ..... | 51        |
| <b>Bibliografia .....</b>                        | <b>53</b> |

# Sommario

## Problema e Contesto

Le malattie cardiovascolari rappresentano la principale causa di mortalità globale; nei pazienti sottoposti a cardiocirurgia maggiore (bypass coronarico, sostituzione valvolare), la fase riabilitativa post-operatoria è determinante per l'esito a lungo termine. La valutazione funzionale durante la riabilitazione si basa tuttora su scale cliniche soggettive — in particolare la classificazione *New York Heart Association* (NYHA) — rilevate in modo discontinuo durante le visite mediche. I dispositivi indossabili (*wearable*) dotati di sensori ECG e accelerometrici triassiali MEMS offrono la prospettiva di un monitoraggio continuo e oggettivo dello stato cardiaco e motorio del paziente, ma richiedono algoritmi di analisi validati su dati clinici reali.

## Contributo Originale

Il presente elaborato sviluppa e valida una pipeline di analisi automatica applicata a registrazioni wearable (ECG monoderivazione a 130 Hz e accelerometro triassiale MEMS a 200 Hz) raccolte su pazienti in riabilitazione cardiaca post-chirurgica. A differenza della letteratura esistente — che tipicamente tratta separatamente la classificazione dell'attività motoria e l'analisi della variabilità della frequenza cardiaca (HRV) — il contributo originale consiste nell'analisi quantitativa della **correlazione lineare tra feature accelerometriche e feature HRV** come fondamento fisiopatologico che giustifica l'integrazione dei due canali sensoriali, seguita da classificazione multi-obiettivo con approccio patient-aware che previene il data leakage paziente — una criticità metodologica spesso trascurata nella letteratura sul machine learning clinico.

## Metodologia

La pipeline comprende: (i) preprocessing del segnale ECG (filtro Butterworth 4° ordine zero-phase 0,5–40 Hz, algoritmo Pan-Tompkins per il rilevamento dei picchi R, calcolo degli intervalli R-R) e del segnale accelerometrico (separazione componente gravitazionale per asse, filtraggio dinamica 0,3–20 Hz, calcolo della magnitudine vettoriale); (ii) filtraggio della qualità del segnale (SQI su nove metriche per ECG e ACC) che ha selezionato **16.086 finestre valide** su circa 37.000 candidate (43,5 % del totale, con tasso di rigetto del 56,5 %); (iii) estrazione di 72 feature (19 HRV nei domini del tempo, della frequenza e non lineare; 40 ACC cinematiche, spettrali e statistiche; feature cliniche per OBJ3); (iv) analisi di correlazione statistica (Pearson, Spearman, regressione OLS); (v) classificazione con Random Forest, SVM e Regressione Logistica con cross-validazione *StratifiedGroupKFold* che garantisce la separazione completa dei pazienti tra fold di training e test.

## Risultati Principali

L'analisi di correlazione — obiettivo trasversale — dimostra l'esistenza di una relazione statisticamente significativa tra le feature accelerometriche e l'intervallo R-R medio: la feature più correlata è la frequenza dominante della magnitudine accelerometrica (`acc_mag_dom_freq`) con  $r = -0.298$ ,  $\rho = -0.320$ ,  $p \approx 0$ , e coefficiente di determinazione massimo  $R^2 \approx 9\%$ . Il segno negativo è fisiologicamente coerente: all'aumentare della cadenza di movimento corrisponde una diminuzione dell'intervallo R-R, ovvero un aumento della frequenza cardiaca.

Tre obiettivi di classificazione sono stati affrontati: (OBJ1) riconoscimento del tipo di attività motoria tra cinque test clinici standardizzati (F1 pesato pari a **0,782** con Random Forest); (OBJ2) distinzione binaria riposo/attività (F1 = **0,933**, accuratezza 95,2 %); (OBJ3) stima della classe funzionale NYHA con validazione patient-aware che ha prodotto F1 = **0,590**, risultato confrontabile con la letteratura su task analoghi. A ulteriore verifica della generalizzabilità, la pipeline è stata applicata senza modifiche a un secondo dataset indipendente (SCG-RHC, PhysioNet, 83 pazienti con insufficienza cardiaca), ottenendo F1 = 0,647 nella predizione dello scompenso emodinamico.

## Struttura dell'Elaborato

Il **Capitolo 1** (Introduzione) inquadra il problema clinico e il contesto tecnologico, espone gli obiettivi e il contributo originale del lavoro.

Il **Capitolo 2** (Background Teorico) fornisce i fondamenti di HRV, di accelerometria MEMS, di qualità del segnale e di machine learning supervisionato.

Il **Capitolo 3** (Dataset e Metodi) descrive il dataset sperimentale, la pipeline di preprocessing, l'estrazione delle feature e la strategia di validazione.

Il **Capitolo 4** (Analisi della Correlazione  $ACC \leftrightarrow HRV$ ) presenta i risultati statistici della correlazione inter-modale, che costituisce il nucleo scientifico dell'elaborato.

Il **Capitolo 5** (Classificazione Automatica) riporta i risultati dei tre obiettivi con analisi degli errori, feature importance e confronto con la letteratura.

Il **Capitolo 6** (Conclusioni e Sviluppi Futuri) sintetizza i risultati, discute le implicazioni cliniche e i limiti del lavoro, e propone le direzioni di sviluppo futuro, inclusa la validazione esterna su dataset SCG-RHC.



## Elenco delle Figure

|                                                                                                               |    |
|---------------------------------------------------------------------------------------------------------------|----|
| Figura 4.1: Heatmap delle correlazioni ACC–HRV (Pearson $r$ ). .....                                          | 31 |
| Figura 4.2: Scatter plot: SMA vs RR medio, retta OLS, colore per attività. ....                               | 31 |
| Figura 5.1: Matrice di confusione normalizzata — OBJ1, Random Forest. ....                                    | 34 |
| Figura 5.2: Matrice di confusione — OBJ2, Random Forest. ....                                                 | 35 |
| Figura 5.3: Matrice di confusione — OBJ3a (4 classi NYHA), Random Forest con StratifiedGroupKFold. ....       | 37 |
| Figura 5.4: Feature importance (indice di Gini) — OBJ1, Random Forest. ....                                   | 38 |
| Figura 5.5: Feature importance (indice di Gini) — OBJ2 (REST vs ACTIVITY), classificatore Random Forest. .... | 39 |
| Figura 5.6: Feature importance — OBJ3b (NYHA binario), Random Forest. ....                                    | 40 |
| Figura 5.7: Confronto dell’F1-score pesato per tutti i modelli e obiettivi. ....                              | 41 |

## Elenco delle Tabelle

|                                                                                                                                              |    |
|----------------------------------------------------------------------------------------------------------------------------------------------|----|
| Tabella 2.1: Feature estratte dal segnale accelerometrico triassiale (40 feature per finestra). ....                                         | 14 |
| Tabella 3.1: Test clinici registrati per ciascun paziente. ....                                                                              | 21 |
| Tabella 3.2: Soglie del Signal Quality Index per ECG e ACC. ....                                                                             | 23 |
| Tabella 3.3: Distribuzione delle operazioni tra livello edge e livello cloud. ....                                                           | 27 |
| Tabella 4.1: Top 10 feature ACC più correlate con l’intervallo RR medio, calcolate sull’intero dataset ( $n = 16.086$ finestre valide). .... | 29 |
| Tabella 4.2: Feature ACC più correlata con RR medio per tipo di attività e per il periodo di riposo (REST). ....                             | 30 |
| Tabella 5.1: Riepilogo dei risultati di classificazione per i tre obiettivi. ....                                                            | 33 |
| Tabella 6.1: Risultati classificazione CDecomp (Compensato vs Scompensato) sul dataset SCG-RHC. ....                                         | 47 |

# 1 Introduzione

## 1.1 Contesto e Motivazione

Le malattie cardiovascolari (MCV) rappresentano la principale causa di mortalità nei paesi industrializzati: secondo i dati dell'Organizzazione Mondiale della Sanità, ogni anno circa 17,9 milioni di persone nel mondo perdono la vita per eventi cardiovascolari, corrispondenti al 32% di tutti i decessi globali [1]. In Europa, le MCV sono responsabili di oltre 3,9 milioni di morti l'anno, con un impatto economico stimato superiore a 210 miliardi di euro annui tra costi diretti di assistenza sanitaria, perdita di produttività e caregiving informale. In Italia, le patologie cardiache costituiscono la prima causa di morte, con circa 230.000 decessi attribuibili ogni anno, e generano un numero elevato di ricoveri ospedalieri, molti dei quali sfociano in interventi di cardiocirurgia maggiore — bypass aortocoronarico, sostituzione valvolare, correzione di cardiopatie congenite — la cui fase post-operatoria è determinante per l'esito clinico a lungo termine [1].

La riabilitazione cardiaca strutturata — intesa come l'insieme coordinato di interventi che comprendono esercizio fisico supervisionato, educazione terapeutica e supporto psicologico — ha dimostrato di ridurre la mortalità cardiovascolare del 20–30% e il rischio di reospedalizzazione del 18–28% rispetto ai pazienti non riabilitati [2]. Nonostante tali evidenze, la percentuale di pazienti cardiocirurgici che accedono effettivamente a programmi di riabilitazione formale rimane insoddisfacente: stime recenti indicano che in Europa solo il 30–50% dei candidati idonei viene arruolato in un percorso riabilitativo strutturato, con ampie disparità geografiche e socioeconomiche. Le cause sono molteplici: scarsa disponibilità di centri specializzati, difficoltà logistiche, sottorefferral da parte dei cardiologi e, non ultimo, la difficoltà di valutare oggettivamente e in modo continuativo il progresso funzionale del paziente al di fuori dell'ambiente clinico.

La valutazione dello stato funzionale durante la riabilitazione si basa tutt'oggi in larga misura su scale cliniche soggettive. Tra queste, la classificazione della *New York Heart Association* (NYHA) stratifica i pazienti in quattro classi di gravità — dalla classe I (assenza di sintomi) alla classe IV (sintomi a riposo) — in funzione della limitazione dell'attività fisica riferita dal soggetto stesso [3]. Questa soggettività costituisce un limite intrinseco: la valutazione dipende dall'interpretazione del clinico e dalla collaborazione del paziente, ed è per sua natura discontinua, rilevata *spot* durante la visita medica piuttosto che in modo continuo nel tempo. Esiste pertanto un gap clinicamente rilevante tra la frequenza delle osservazioni disponibili e la dinamica reale dello stato funzionale del paziente.

### 1.1.1 Wearable Computing e IoT Medicale

Negli ultimi anni, la convergenza tra miniaturizzazione elettronica, wireless body area networks e cloud computing ha determinato l'affermazione del paradigma dell'*Internet of Medical Things* (IoMT): dispositivi indossabili (*wearable*) di piccole dimensioni, a basso consumo e basso costo sono oggi in grado di acquisire in modo continuo segnali biometrici di elevata qualità direttamente sul corpo del paziente [4]. Accelerometri triassiali MEMS (*Micro Electro-Mechanical Systems*), elettrocardiografi monoderivazione, pulsossimetri e sensori di temperatura corporea sono già integrati in dispositivi commerciali o di ricerca indossabili al polso, alla coscia o al torace, e possono trasmettere dati in tempo reale a piattaforme di analisi remota. Questa trasformazione apre la prospettiva di un monitoraggio obiettivo, continuo e non invasivo dello stato cardiaco e motorio del paziente, estendendo idealmente la sorveglianza clinica dall'ambulatorio all'ambiente domestico.

La digitalizzazione della sanità — con l'adozione crescente di cartelle cliniche elettroniche, piattaforme di *remote patient monitoring* e sistemi di supporto decisionale basati su intelligenza artificiale — crea un terreno fertile per l'integrazione di questi dati nei percorsi di cura. Il Piano Nazionale di Ripresa e Resilienza (PNRR) italiano, nella sua Missione 6 dedicata alla salute, ha esplicitamente identificato la telemedicina e il monitoraggio remoto come leve strategiche per migliorare la continuità assistenziale e ridurre la pressione sulle strutture ospedaliere. In questo contesto, la disponibilità di algoritmi di *machine learning* validati clinicamente su dati reali di pazienti in riabilitazione assume un valore scientifico e applicativo di rilievo.

### 1.1.2 Variabilità della Frequenza Cardiaca e Segnali Accelerometrici

La variabilità della frequenza cardiaca (HRV, *Heart Rate Variability*) — ovvero la fluttuazione temporale degli intervalli R-R nell'ECG — è un indicatore consolidato della funzione del sistema nervoso autonomo cardiaco e del bilancio simpato-vagale [5]. Indici nel dominio del tempo (SDNN, RMSSD, pNN50), nel dominio della frequenza (LF, HF, LF/HF) e indici non lineari (Sample Entropy, DFA — Detrended Fluctuation Analysis —  $\alpha_1$ , SD1/SD2) forniscono una caratterizzazione multidimensionale della regolazione autonoma [6], [7], [8]. Valori ridotti di HRV sono associati a prognosi peggiore in pazienti cardiopatici, a maggiore rischio di aritmie e a ridotta capacità funzionale. Tuttavia, l'estrazione affidabile di feature HRV richiede segnali ECG di qualità sufficiente, il che costituisce una sfida nei contesti ambulatoriali e domiciliari.

L'ipotesi centrale del presente elaborato è che i segnali accelerometrici — facilmente acquisibili con dispositivi *consumer* a basso costo, robusti al rumore elettrico e non richiedenti elettrodi cutanei — siano correlabili in modo quantificabile con le feature HRV, consentendo una stima indiretta dello stato cardiaco e funzionale a partire dal solo segnale di movimento. Questa ipotesi è motivata dalla fisiopatologia: il livello di attività

motoria influenza la frequenza cardiaca e, attraverso la modulazione autonoma, gli indici HRV; la coerenza tra i due canali sensoriali è dunque attesa, ma la sua entità e struttura statistica deve essere quantificata empiricamente su dati reali.

Il dataset analizzato nel presente elaborato comprende registrazioni di pazienti cardiocirurgici durante protocolli riabilitativi strutturati, per un totale di **16.086 finestre temporali** di 30 secondi ciascuna, estratte dopo un rigoroso filtraggio della qualità del segnale (SQI, *Signal Quality Index*) da una base iniziale di circa 37.000 finestre candidate — con un tasso di rigetto pari al 56,5%. I segnali acquisiti includono un canale ECG monoderivazione campionato a 130 Hz e un accelerometro triassiale MEMS campionato a 200 Hz, raccolti durante cinque protocolli clinici standardizzati: test della scala (STAIR), test del cammino di sei minuti (6MWT), *Timed Up and Go* (TUG), test in bicicletta (VELO) e analisi del cammino strumentale (GAIT\_ANALYSIS).

## 1.2 Obiettivi del Progetto

Il presente elaborato si propone di sviluppare e validare una pipeline di analisi automatica applicata a dati acquisiti da pazienti in fase di riabilitazione cardiaca post-chirurgica. La pipeline integra fasi di preprocessing del segnale, estrazione di feature multimodali, selezione delle variabili, addestramento di modelli di classificazione e analisi statistica della correlazione inter-modale. Gli obiettivi specifici sono i seguenti.

**Obiettivo 1 — Classificazione del tipo di attività motoria (OBJ1).** Costruire un classificatore multiclasse in grado di distinguere cinque tipologie di attività motoria (STAIR, 6MWT, TUG, VELO, GAIT\_ANALYSIS) a partire dalle 72 feature estratte dai segnali accelerometrici ed ECG. Questo obiettivo mira a verificare la capacità dei segnali wearable di caratterizzare automaticamente il comportamento motorio del paziente, e fornisce una base per la contestualizzazione clinica automatica delle misurazioni. Il classificatore *Random Forest* raggiunge un F1-score ponderato di **0.782** su questo task.

**Obiettivo 2 — Distinzione tra stato di riposo e attività (OBJ2).** Sviluppare un classificatore binario (REST vs. ACTIVITY) che validi la qualità del sensore e la rappresentatività delle feature estratte. Questo task, sebbene concettualmente più semplice, è cruciale: un risultato elevato costituisce la condizione necessaria per la fiducia negli obiettivi più ambiziosi. Il modello *Random Forest* raggiunge un F1-score ponderato di **0.933**, confermando la coerenza e la discriminabilità delle feature estratte.

**Obiettivo 3 — Stima della classe NYHA (OBJ3).** Addestrare un modello di classificazione per la stima della classe funzionale NYHA del paziente a partire dalle feature HRV e accelerometriche. Questo è l'obiettivo clinicamente più ambizioso: un sistema capace di stimare la classe NYHA in modo obiettivo e continuo potrebbe affiancare il giudizio clinico, consentire un monitoraggio tra una visita e l'altra e intercettare

tempestivamente deterioramenti funzionali. Il classificatore *Random Forest* raggiunge un F1-score ponderato di **0.590**, evidenziando la difficoltà del task e la necessità di feature aggiuntive o di modelli più espressivi per approssimazioni clinicamente utili.

**Obiettivo trasversale — Analisi di correlazione ACC $\Rightarrow$ HRV.** Analizzare quantitativamente la relazione statistica tra le feature accelerometriche e le feature HRV tramite correlazione di Pearson, correlazione di Spearman e regressione lineare OLS multipla. Questo obiettivo costituisce il fondamento teorico che giustifica l’approccio proposto: se esiste una relazione misurabile tra movimento e regolazione autonoma, allora i segnali accelerometrici possono veicolare, anche indirettamente, informazione sullo stato cardiaco. I risultati mostrano correlazioni statisticamente significative ma di entità moderata ( $r = -0.298$ ,  $\rho = -0.320$  tra la frequenza dominante dell’accelerometro e l’intervallo RR medio, con  $R^2_{\max} \approx 9\%$ ), il che suggerisce che la relazione sia reale ma non lineare e non riducibile a un singolo predittore.

### 1.3 Contributo Originale

Il presente elaborato fornisce i seguenti contributi originali rispetto allo stato dell’arte nel campo del monitoraggio wearable in riabilitazione cardiaca.

1. **Pipeline riproducibile end-to-end.** È stata progettata e implementata una pipeline modulare in Python che copre l’intero ciclo di vita del dato: dalla lettura dei file raw in formato WFDB, al preprocessing del segnale ECG con algoritmo di Pan-Tompkins [9], all’estrazione di 19 feature HRV con la libreria NeuroKit2 [10], all’estrazione di 40 feature accelerometriche nei domini del tempo, della frequenza (tramite trasformata di Lomb-Scargle [11]) e statistico, fino all’addestramento e valutazione dei modelli. Ogni fase è parametrizzabile e documentata, garantendo la riproducibilità completa dei risultati.
2. **Filtraggio della qualità del segnale con SQI certificato.** Su una base iniziale di circa 37.000 finestre temporali candidate, l’applicazione di un indice di qualità del segnale (*Signal Quality Index*) ha selezionato **16.086 finestre valide** (43,5% del totale), con un tasso di rigetto del **56,5%**. Questo filtraggio rigoroso garantisce che tutti i modelli siano addestrati e valutati su dati di qualità clinicamente adeguata, una scelta metodologica spesso trascurata nella letteratura.
3. **Validazione con GroupKFold per assenza di data leakage paziente.** La suddivisione dei dati in training e test set è stata eseguita con uno schema *StratifiedGroupKFold* che garantisce la separazione completa tra le finestre dello stesso paziente nelle diverse fold. Questa scelta previene il *data leakage* paziente — una delle principali fonti di sovrastima delle performance nei lavori di machine learning su dati clinici — e rende i risultati generalizzabili a pazienti non visti durante l’addestramento.

4. **Analisi di correlazione ACC $\Rightarrow$ HRV su dataset clinico reale.** È stata condotta una sistematica analisi di correlazione di Pearson e Spearman tra tutte le coppie di feature accelerometriche e HRV, corredata da regressione lineare OLS. Il coefficiente di correlazione più elevato osservato è  $r = -0.298$  ( $\rho_{\text{Spearman}} = -0.320$ ) tra la frequenza dominante dell'accelerometro e il RR medio, con un coefficiente di determinazione massimo  $R_{\text{max}}^2 \approx 9\%$ . Questi risultati quantificano i limiti della linearità nella relazione ACC-HRV e motivano l'adozione di approcci non lineari per lavori futuri.
5. **Risultati di classificazione multi-obiettivo su dati cardiocirurgici.** Sono stati addestrati e confrontati tre famiglie di classificatori — *Random Forest* [12], *Support Vector Machine* [13] e regressione logistica — su tre task di crescente complessità clinica. Il *Random Forest* risulta il modello dominante su tutti e tre gli obiettivi, con F1-score ponderato di 0.933 (OBJ2), 0.782 (OBJ1) e 0.590 (OBJ3). Il bilanciamento delle classi è gestito tramite sovracampionamento SMOTE [14] e class weighting.

## 1.4 Struttura dell'Elaborato

Il presente elaborato è organizzato in sei capitoli, ciascuno dei quali affronta un aspetto distinto del problema, dalla revisione della letteratura fino alla discussione critica dei risultati.

**Capitolo 2 — Background Teorico.** Il capitolo introduce i fondamenti teorici necessari alla comprensione del lavoro: la fisiologia della variabilità della frequenza cardiaca e le misure standardizzate dalla Task Force ESC/NASPE [5] nei domini del tempo, della frequenza e non lineare; i principi di funzionamento degli accelerometri MEMS e le feature cinematiche e spettrali estratte dal segnale di movimento; le metriche di qualità del segnale (SQI) e i metodi di machine learning supervisionato impiegati (Random Forest, SVM, Logistic Regression) con particolare attenzione al problema del data leakage in dataset con struttura gerarchica paziente-finestra.

**Capitolo 3 — Dataset e Metodi.** Il capitolo descrive in dettaglio il dataset di pazienti cardiocirurgici in riabilitazione: caratteristiche demografiche e cliniche della coorte, i protocolli di acquisizione dei cinque test (STAIR, 6MWT, TUG, VELO, GAIT\_ANALYSIS), le specifiche tecniche dei sensori (ECG 130 Hz, ACC 200 Hz), e la procedura di segmentazione in finestre da 30 s con overlap 50%. Viene illustrata la pipeline di preprocessing — filtraggio Butterworth, rilevamento R-peaks con Pan-Tompkins, indice SQI su nove metriche — e la strategia di estrazione delle 72 feature (19 HRV, 40 ACC, feature cliniche). Infine vengono descritte le tre varianti sperimentali per OBJ3 e la strategia di cross-validazione adottata.

**Capitolo 4 — Analisi della Correlazione ACC↔HRV.** Il capitolo presenta i risultati dell’analisi statistica della correlazione tra feature accelerometriche e feature HRV: metodologia (Pearson, Spearman, OLS), tabella delle top-10 feature ACC più correlate con l’intervallo R-R medio su 16.086 finestre, analisi per tipo di attività con identificazione della feature ottimale per ciascun test, heatmap di correlazione e scatter plot con rette di regressione. La sezione conclusiva discute le implicazioni cliniche e fisiopatologiche dei risultati.

**Capitolo 5 — Classificazione Automatica.** Il capitolo riporta i risultati della classificazione automatica per i tre obiettivi, con F1-score, accuratezza, macro- e weighted-precision/recall, matrici di confusione e analisi degli errori di classificazione. Per OBJ3 vengono presentate le tre varianti sperimentali (4 classi, binario NYHA  $\leq$  II vs  $\geq$  III, aggregazione paziente con LOOCV). La feature importance del Random Forest è analizzata per ciascun obiettivo, e vengono identificate le feature più discriminative e la loro interpretazione clinica. Il capitolo si chiude con una discussione critica dei limiti sperimentali.

**Capitolo 6 — Conclusioni e Sviluppi Futuri.** Il capitolo sintetizza i risultati conseguiti rispetto agli obiettivi prefissati, ne valuta le implicazioni cliniche per il monitoraggio continuo nella riabilitazione cardiaca, e delinea i limiti del lavoro: dimensione del campione, soggettività dell’etichetta NYHA, assenza di validazione esterna, ECG monoderivazione. Vengono infine proposte le direzioni di sviluppo futuro: approcci deep learning su segnale grezzo (CNN 1D, LSTM — Long Short-Term Memory — Transformer), classificazione morfologica ECG, analisi longitudinale del percorso riabilitativo, integrazione in architetture di telemedicina e applicazione di tecniche di XAI per l’interpretabilità clinica dei modelli.

## 2 Background Teorico

Questo capitolo fornisce le basi teoriche necessarie alla comprensione del sistema sviluppato. Vengono illustrati i principi della variabilità della frequenza cardiaca (HRV), le caratteristiche del segnale accelerometrico, i criteri di qualità del segnale e i fondamenti degli algoritmi di apprendimento automatico impiegati nel progetto. Ogni sezione è corredata delle definizioni formali, dei range fisiologici di riferimento e delle scelte implementative adottate nel sistema.

### 2.1 Variabilità della Frequenza Cardiaca

#### 2.1.1 Definizione e Rilevanza Clinica

La variabilità della frequenza cardiaca (Heart Rate Variability, HRV) è definita come la fluttuazione degli intervalli di tempo intercorrenti tra battiti cardiaci consecutivi, comunemente denominati intervalli RR o NN [5]. Tale variabilità riflette la capacità del sistema nervoso autonomo (SNA) di modulare l'attività del nodo senoatriale in risposta a stimoli interni ed esterni, e costituisce pertanto un indicatore indiretto non invasivo dell'equilibrio simpato-vagale.

Dal punto di vista fisiologico, l'HRV è determinata dall'interazione tra il ramo simpatico e quello parasimpatico del SNA: l'attivazione vagale (parasimpatica) determina un rallentamento della frequenza cardiaca e un aumento della variabilità a breve termine, mentre l'attivazione simpatica produce l'effetto opposto [5]. Questo equilibrio dinamico è influenzato da numerosi fattori, tra cui lo stato di salute cardiovascolare, il livello di allenamento fisico, lo stress psicologico, la postura e la fase del ciclo respiratorio.

La rilevanza clinica dell'HRV è ampiamente documentata nella letteratura scientifica. Valori ridotti di HRV sono stati associati a un aumentato rischio di mortalità cardiovascolare, a condizioni di scompenso cardiaco, a neuropatia diabetica autonoma e a stati di stress cronico [1], [2]. In ambito riabilitativo, il monitoraggio longitudinale dell'HRV consente di valutare il recupero funzionale del sistema nervoso autonomo in seguito a eventi cardiaci acuti, fornendo indicatori oggettivi della progressione del paziente secondo la classificazione NYHA [3].

Nel presente lavoro, l'HRV è estratta a partire dalla serie temporale degli intervalli RR rilevati mediante ECG campionato a 130 Hz. Il segnale grezzo è sottoposto a filtraggio passa-banda Butterworth del quarto ordine zero-phase con banda passante compresa tra 0,5 Hz e 40 Hz, al fine di eliminare la deriva della linea di base e gli artefatti ad alta frequenza prima del rilevamento dei picchi R.



### 2.1.2 Algoritmo Pan-Tompkins

Il rilevamento dei picchi R nell'ECG è effettuato mediante l'algoritmo di Pan-Tompkins [9], uno dei metodi più diffusi e robusti per la detezione del complesso QRS. L'algoritmo si articola in cinque stadi sequenziali.

Il **primo stadio** consiste nel filtraggio passa-banda, che elimina le componenti a bassa frequenza (artefatti da movimento, deriva della linea di base) e quelle ad alta frequenza (rumore muscolare, interferenze di rete). Nel **secondo stadio** viene calcolata la derivata prima del segnale filtrato, enfatizzando le regioni a rapida variazione di ampiezza tipiche del complesso QRS:

$$y[n] = \frac{1}{8T_s}(2x[n] + x[n-1] - x[n-3] - 2x[n-4])$$

dove  $T_s = 1/130$  s è il periodo di campionamento. Nel **terzo stadio** il segnale derivato viene elevato al quadrato, rendendo tutti i valori positivi e amplificando ulteriormente le regioni di interesse:

$$z[n] = (y[n])^2$$

Il **quarto stadio** applica un filtro di integrazione a finestra mobile (Moving Window Integration, MWI) di ampiezza  $W = 150$  ms, che produce un involucro con un unico picco in corrispondenza del complesso QRS:

$$w[n] = \frac{1}{N_W} \sum_{k=n-(N_W-1)}^n z[k]$$

Il **quinto stadio** implementa un sistema di soglie adattive, aggiornate dinamicamente in funzione dei picchi rilevati, distinguendo i veri picchi QRS dai falsi positivi. Le soglie vengono calibrate separatamente per il segnale filtrato e per il segnale integrato, con una strategia di ricerca nella regione refrattaria cardiaca (200 ms dopo ogni picco) per il recupero dei battiti mancati.

Dopo la detezione, gli intervalli RR vengono sottoposti a un controllo di plausibilità fisiologica: sono scartati gli intervalli inferiori a 300 ms (frequenza cardiaca superiore a 200 bpm) o superiori a 2000 ms (inferiori a 30 bpm), nonché gli intervalli che differiscono di oltre il 20% dalla mediana locale degli ultimi cinque battiti.

### 2.1.3 Misure Temporalì dell'HRV

Le misure temporalì dell'HRV sono calcolate direttamente sulla serie degli intervalli RR e rappresentano le stime statistiche più intuitive della variabilità cardiaca [5]. Per ciascuna finestra di 30 s vengono richiesti almeno 15 intervalli RR validi; la stima viene scartata in caso contrario.

**SDNN — Deviazione Standard degli intervalli NN**

L'SDNN (Standard Deviation of Normal-to-Normal intervals) è la misura temporale più generale dell'HRV globale, riflettendo tutte le componenti cicliche responsabili della variabilità:

$$SDNN = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (RR_i - \overline{RR})^2}$$

dove  $N$  è il numero di intervalli RR validi e  $\overline{RR}$  è la loro media. Il range fisiologico per soggetti adulti sani è tipicamente 40–80 ms su registrazioni brevi di cinque minuti [5]. Valori di SDNN inferiori a 50 ms sono considerati indice di ridotta variabilità autonoma e sono associati a outcome cardiovascolari sfavorevoli.

### **RMSSD — Root Mean Square of Successive Differences**

L'RMSSD è l'indice temporale più sensibile all'attività parasimpatica (vagale) ad alta frequenza:

$$RMSSD = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} (RR_{i+1} - RR_i)^2}$$

Il range fisiologico per adulti sani è 20–50 ms a riposo, con valori più elevati negli atleti ben allenati. L'RMSSD è fortemente correlato con la potenza in banda HF dello spettro di frequenza ed è preferito all'SDNN per valutazioni dell'attività vagale a breve termine, poiché risulta meno influenzato dalle tendenze a lungo termine della serie RR.

### **pNN50 — Percentuale di differenze successive superiori a 50 ms**

Il pNN50 esprime la percentuale di coppie di intervalli RR consecutivi la cui differenza in valore assoluto supera la soglia di 50 ms:

$$pNN50 = \frac{|\{(RR_{i+1}, RR_i) : |RR_{i+1} - RR_i| > 50 \text{ ms}\}|}{N-1} \times 100$$

I valori fisiologici tipici variano tra il 5% e il 30% in soggetti sani a riposo. Il pNN50 condivide con l'RMSSD la sensibilità all'attività vagale; tuttavia, è statisticamente meno stabile dell'RMSSD su campioni di ridotte dimensioni, per cui viene impiegato come indice complementare.

### **CV<sub>RR</sub> — Coefficiente di Variazione degli intervalli RR**

Il coefficiente di variazione normalizza la deviazione standard rispetto alla media, rendendola adimensionale e indipendente dalla frequenza cardiaca assoluta:

$$CV_{RR} = \frac{SDNN}{\overline{RR}} \times 100$$

Il range fisiologico è approssimativamente 2–8% in condizioni di riposo. Nel sistema, il  $CV_{RR}$  svolge anche il ruolo di criterio di qualità del segnale: finestre con  $CV_{RR} >$

40% vengono classificate come artefatte, poiché tale valore eccede qualsiasi variabilità sinusale fisiologicamente plausibile.

#### 2.1.4 Misure Frequenziali dell'HRV

L'analisi spettrale dell'HRV decompone la varianza degli intervalli RR nelle sue componenti oscillatorie, consentendo la separazione delle influenze simpatiche e parasimpatiche sul controllo cardiaco [5]. Le bande di frequenza convenzionalmente analizzate sono:

- **VLF** (Very Low Frequency, 0,003–0,04 Hz): associata a meccanismi di termoregolazione, attività del sistema renina-angiotensina e peptidi vasoattivi;
- **LF** (Low Frequency, 0,04–0,15 Hz): riflette sia l'attività simpatica sia quella parasimpatica, con predominanza simpatica in posizione ortostatica;
- **HF** (High Frequency, 0,15–0,4 Hz): correlata all'aritmia sinusale respiratoria (RSA) e indice dell'attività vagale;
- **Rapporto LF/HF**: indice di bilanciamento simpato-vagale, con valori tipici tra 1,5 e 2,0 a riposo in posizione supina.

#### Stima spettrale con il periodogramma di Lomb-Scargle

La serie degli intervalli RR è intrinsecamente non equidistante nel tempo, in quanto ogni intervallo ha durata diversa. L'impiego del periodogramma di Lomb-Scargle [11] consente di stimare lo spettro di potenza direttamente sulla serie temporale non uniforme, evitando la necessità di ricampionamento e le distorsioni spettrali che esso comporta. Il periodogramma normalizzato è definito come:

$$P_{LS(f)} = \frac{1}{2\sigma^2} \left[ \frac{\left( \sum_j (x_j - \bar{x}) \cos(2\pi f(t_j - \tau)) \right)^2}{\sum_j \cos^2(2\pi f(t_j - \tau))} + \frac{\left( \sum_j (x_j - \bar{x}) \sin(2\pi f(t_j - \tau)) \right)^2}{\sum_j \sin^2(2\pi f(t_j - \tau))} \right]$$

dove  $x_j = RR_j$  sono i valori degli intervalli,  $t_j$  i rispettivi istanti di inizio,  $\bar{x}$  e  $\sigma^2$  la media e la varianza della serie, e  $\tau$  uno sfasamento che garantisce l'ortogonalità sinusoidale. Il sistema richiede un minimo di 30 intervalli RR per la stima spettrale, al fine di garantire una risoluzione frequenziale adeguata. Il calcolo è effettuato tramite la libreria NeuroKit2 [10], che implementa l'integrazione numerica della potenza nelle bande di frequenza definite mediante il metodo dei trapezi.

#### 2.1.5 Misure Geometriche e Non-Lineari dell'HRV

Le misure geometriche e non-lineari catturano aspetti della dinamica cardiaca non accessibili alle analisi lineari nel dominio del tempo e della frequenza [6], [7], [8].

##### Analisi del Diagramma di Poincaré

Il diagramma di Poincaré rappresenta ogni intervallo RR in funzione del successivo, costruendo una mappa di ritardo di ordine 1. Dalla distribuzione dei punti si ricavano due indici mediante fitting ellissoidale:

- SD1 misura la dispersione perpendicolare alla diagonale identità, correlata alla variabilità a breve termine (attività vagale):

$$SD1 = \frac{RMSSD}{\sqrt{2}}$$

- SD2 misura la dispersione lungo la diagonale identità, correlata alla variabilità a lungo termine:

$$SD2 = \sqrt{2 \cdot SDNN^2 - \frac{1}{2}RMSSD^2}$$

Il rapporto SD1 / SD2 fornisce un indice dell'equilibrio tra variabilità a breve e lungo termine, con valori ridotti tipici di stati di stress autonomico.

### **Misure Geometriche sull'Istogramma RR: HTI e TINN**

L'HRV Triangular Index (HTI) è definito come il rapporto tra il numero totale di intervalli RR e l'altezza del bin modale dell'istogramma della distribuzione RR:

$$HTI = \frac{N}{D(RR_{mode})}$$

dove  $D(RR_{mode})$  è l'altezza del bin più frequente. Nel sistema, l'istogramma è costruito con bin di ampiezza  $1/128$  s  $\approx 7,8$  ms, in accordo con le raccomandazioni della Task Force [5]. Il TINN (Triangular Interpolation of NN interval histogram) è la base della triangolazione lineare ottimale dell'istogramma in millisecondi, e costituisce una stima robusta della variabilità globale, meno sensibile agli outlier rispetto all'SDNN.

### **Entropia Approssimata (ApEn)**

L'entropia approssimata, introdotta da Pincus [6], quantifica la regolarità o prevedibilità della serie RR: valori elevati corrispondono a segnali più irregolari (maggiore complessità fisiologica), valori bassi a segnali più regolari (ridotta variabilità autonoma):

$$ApEn(m, r, N) = \varphi^m(r) - \varphi^{m+1}(r)$$

dove  $\varphi^{m(r)} = (N - m)^{-1} \sum_i \ln C_i^{m(r)}$ ,  $C_i^{m(r)}$  è la probabilità che due sequenze di lunghezza  $m$  siano simili entro la tolleranza  $r$ . I parametri tipici sono  $m = 2$  e  $r = 0,2 \times \sigma_{RR}$ .

### **Entropia Campionaria (SampEn)**

La Sample Entropy [7] risolve alcuni bias statistici dell'ApEn eliminando l'autocomparabilità delle sequenze:

$$\text{SampEn}(m, r, N) = -\ln \frac{A^m(r)}{B^m(r)}$$

dove  $A^m(r)$  è il numero di coppie di template di lunghezza  $m + 1$  simili entro  $r$ , e  $B^m(r)$  è il numero di coppie di lunghezza  $m$  simili. La SampEn è meno dipendente dalla lunghezza del segnale e più consistente statisticamente rispetto all'ApEn, risultando preferita su finestre brevi di 30 s.

### Analisi delle Fluttuazioni Detrended (DFA)

La DFA [8] analizza le auto-correlazioni a lungo raggio della serie RR, stimando l'esponente di scaling  $\alpha$  che caratterizza la struttura frattale del segnale:

$$F(n) = \sqrt{\frac{1}{N} \sum_{k=1}^N [y(k) - y_n(k)]^2} \sim n^\alpha$$

dove  $y(k)$  è la serie integrata e  $y_n(k)$  è il trend locale su segmenti di lunghezza  $n$ . Si distinguono due esponenti:

- $\alpha_1$  (scala corta,  $n = 4\text{--}16$ ): sensibile alla variabilità a breve termine, con valori fisiologici tipici  $\approx 1,0\text{--}1,2$ ;
- $\alpha_2$  (scala lunga,  $n = 16\text{--}64$ ): riflette correlazioni a lungo termine, con valori tipici  $\approx 0,9\text{--}1,1$ .

Valori di  $\alpha_1 < 0,75$  sono stati associati a prognosi sfavorevole nei pazienti con insufficienza cardiaca congestizia [2].

## 2.2 Segnale Accelerometrico

### 2.2.1 Principio di Funzionamento dei Sensori MEMS

Gli accelerometri impiegati nei dispositivi indossabili sono basati sulla tecnologia MEMS (Micro-Electro-Mechanical Systems), che sfrutta la deformazione di strutture capacitive micrometriche per misurare l'accelerazione subita dal sensore [4]. Il segnale grezzo rilevato dal sensore triassiale è la somma vettoriale di due componenti fisicamente distinte:

$$\mathbf{a}_{\text{tot}}(t) = \mathbf{a}_{\text{grav}}(t) + \mathbf{a}_{\text{dyn}}(t)$$

La componente gravitazionale  $\mathbf{a}_{\text{grav}}$  è un vettore di ampiezza costante pari a 1 g (9,81 m/s<sup>2</sup>) diretto verso il basso, la cui proiezione sugli assi del sensore varia solo al variare dell'orientamento del dispositivo rispetto alla verticale. La componente dinamica  $\mathbf{a}_{\text{dyn}}$  riflette invece i movimenti e le vibrazioni del soggetto ed è quella di interesse motorio.

Nei sensori MEMS triassiali, la struttura meccanica condivisa degli assi introduce un accoppiamento residuo tra le componenti misurate, noto come *diafonia* (*crosstalk*): un'accelerazione applicata lungo un asse si riflette parzialmente sugli assi ortogonali, introducendo un errore sistematico nelle misure assiali. Per ridurre l'impatto, il sistema adotta due strategie complementari: (1) il calcolo della magnitudine vettoriale  $M(t) = \sqrt{a_x^2 + a_y^2 + a_z^2}$ , che produce una misura scalare invariante all'orientamento e immune dalla diafonia direzionale; (2) l'estrazione delle correlazioni inter-asse ( $\rho_{xy}$ ,  $\rho_{xz}$ ,  $\rho_{yz}$ ) come feature esplicite, che ne quantificano l'entità residua e la forniscono al classificatore come informazione aggiuntiva.

Nel sistema, il segnale accelerometrico è campionato a 200 Hz. La separazione delle due componenti avviene mediante filtraggio frequenziale: un filtro passa-basso con frequenza di taglio a 0,3 Hz isola la componente gravitazionale (variazioni di orientamento lente), mentre un filtro passa-banda 0,3–20 Hz estrae la componente dinamica. Entrambi i filtri sono implementati come filtri Butterworth del quarto ordine zero-phase, per evitare distorsioni di fase che altererebbero la struttura temporale degli eventi motori.

### 2.2.2 Estrazione delle Feature dal Segnale Accelerometrico

Le feature sono estratte su quattro canali: i tre assi ortogonali X, Y, Z e la magnitudine vettoriale M, definita come:

$$M(t) = \sqrt{a_x(t)^2 + a_y(t)^2 + a_z(t)^2}$$

Per ciascun canale vengono calcolate feature statistiche, spettrali e di correlazione inter-asse su finestre di 30 s con overlap del 50%.

| Canale     | Feature            | Simbolo          | Descrizione                                |
|------------|--------------------|------------------|--------------------------------------------|
| X, Y, Z, M | Media              | $\mu$            | Valor medio dell'accelerazione sul canale  |
| X, Y, Z, M | Deviazione std.    | $\sigma$         | Dispersione attorno alla media             |
| X, Y, Z, M | Energia            | $E$              | Somma dei quadrati normalizzata per $N$    |
| X, Y, Z, M | Peak-to-peak       | p2p              | Differenza tra massimo e minimo assoluti   |
| X, Y, Z, M | RMS                | rms              | Radice della media dei quadrati            |
| X, Y, Z, M | Jerk RMS           | jerk             | RMS della derivata prima temporale         |
| X, Y, Z, M | Frequenza dom.     | $f_{\text{dom}}$ | Frequenza a massima densità spettrale      |
| X, Y, Z, M | Energia spettrale  | $E_{\text{sp}}$  | Integrale del PSD in banda 0,3–20 Hz       |
| X, Y, Z, M | Entropia spettrale | $H_{\text{sp}}$  | Irregolarità della distribuzione spettrale |
| M          | SMA                | SMA              | Signal Magnitude Area sui tre assi         |
| XY, XZ, YZ | Correlazione       | $\rho$           | Correlazione di Pearson tra coppie di assi |

**Tabella 2.1:** Feature estratte dal segnale accelerometrico triassiale (40 feature per finestra).

Le formule analitiche delle principali feature statistiche sono:

$$\mu = \frac{1}{N} \sum_{i=1}^N a_i, \quad \sigma = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (a_i - \mu)^2}, \quad E = \frac{1}{N} \sum_{i=1}^N a_i^2$$

$$\text{RMS} = \sqrt{E}, \quad \text{p2p} = \max(\mathbf{a}) - \min(\mathbf{a})$$

Il jerk rappresenta la derivata temporale dell'accelerazione ed è calcolato come:

$$\text{jerk}_{\text{RMS}} = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} \left( \frac{a_{i+1} - a_i}{\Delta} \right)^2}, \quad \Delta t = \frac{1}{200} \text{ s}$$

La Signal Magnitude Area è un indice globale di intensità dell'attività motoria indipendente dall'orientamento del dispositivo:

$$\text{SMA} = \frac{1}{N} \sum_{i=1}^N (|a_x(i)| + |a_y(i)| + |a_z(i)|)$$

L'entropia spettrale misura l'uniformità della distribuzione di potenza in frequenza, con valori prossimi a 0 per segnali quasi-periodici e prossimi a 1 per segnali rumorosi a banda larga:

$$H_{\text{sp}} = - \sum_k p_k \log_2(p_k), \quad p_k = \frac{P(f_k)}{\sum_j P(f_j)}$$

### 2.2.3 Ipotesi sulla Relazione ACC-HRV

L'introduzione delle feature accelerometriche nel modello di classificazione è motivata dall'ipotesi che l'attività motoria del soggetto influenzi sistematicamente i valori di HRV, e che tale influenza sia distinguibile dalla variazione di HRV dovuta allo stato fisiopatologico [4]. In un contesto riabilitativo, i pazienti svolgono esercizi strutturati con intensità crescente: l'HRV durante l'attività motoria controllata differisce da quella a riposo, e tale differenza è modulata dalla capacità di recupero autonomico del soggetto, strettamente legata al livello funzionale secondo la classificazione NYHA [3].

La correlazione incrociata tra la magnitudine accelerometrica e gli indici HRV consente di identificare pattern di risposta cardio-motoria caratteristici di specifici livelli funzionali. L'integrazione delle due sorgenti di informazione — cardiaca e inerziale — mira a fornire al classificatore una rappresentazione più completa dello stato fisiologico rispetto all'uso esclusivo dell'HRV, riducendo l'ambiguità interpretativa che si verifica quando un'elevata variabilità cardiaca può essere attribuita indistintamente a recupero autonomico o ad artefatti motori.

## 2.3 Signal Quality Index

### 2.3.1 Artefatti nei Segnali Fisiologici Indossabili

La qualità dei segnali acquisiti mediante dispositivi indossabili è soggetta a diverse sorgenti di degrado che, se non opportunamente gestite, compromettono l'affidabilità delle feature estratte e le prestazioni del classificatore [4]. Le principali tipologie di artefatti sono:

**Artefatti da movimento** (Motion Artifacts): causati dallo spostamento relativo tra il sensore e la cute del soggetto, generano distorsioni del segnale ECG particolarmente rilevanti nelle bande di frequenza del complesso QRS (5–40 Hz). Il filtraggio zero-phase riduce ma non elimina completamente tali artefatti.

**Distacco dell'elettrodo**: produce una deriva improvvisa o una saturazione del segnale ECG, generando lunghi tratti di segnale piatto (flatline) o a variazione quasi nulla, che falsificano il rilevamento dei picchi R.

**Saturazione del convertitore ADC**: avviene quando l'ampiezza del segnale supera i limiti della dinamica del convertitore analogico-digitale, producendo troncamento (clipping) dei picchi, con conseguente errore nella stima dell'ampiezza QRS.



**Interferenza di rete a 50 Hz:** rumore sinusoidale sovrapposto al segnale ECG per induzione elettromagnetica dalla rete di distribuzione dell'energia, eliminato dal filtraggio passa-banda.

**Artefatti del segnale accelerometrico:** includono vibrazioni meccaniche parasite, urti impulsivi e saturazioni del range di misura del sensore (tipicamente  $\pm 8$  g).

### 2.3.2 Metriche del Signal Quality Index

Il sistema implementa un insieme di soglie automatiche per la classificazione della qualità di ciascuna finestra, separate per il canale ECG e per il canale accelerometrico.

Per il canale ECG, le metriche e le relative soglie di accettazione sono:

- **ecg\_flatline:** frazione di campioni con variazione assoluta inferiore alla soglia minima; accettabile se  $< 5\%$ ;
- **ecg\_clip:** frazione di campioni al limite di saturazione ADC; accettabile se  $< 2\%$ ;
- **ecg\_rr\_quality:** rapporto tra battiti validi e totali rilevati; accettabile se  $> 50\%$ ;
- **ecg\_cv\_rr:** coefficiente di variazione degli intervalli RR; accettabile se  $< 40\%$ ;
- **ecg\_n\_rpeaks:** numero di picchi R rilevati nella finestra; accettabile se  $\geq 5$ .

Per il canale accelerometrico:

- **acc\_flatline:** frazione di campioni a variazione nulla; accettabile se  $< 10\%$ ;
- **acc\_clip:** frazione di campioni in saturazione; accettabile se  $< 2\%$ ;
- **acc\_mag\_range:** range dinamico della magnitudine in mg; accettabile se  $> 5$  mg, per escludere segnali troppo silenziosi indicativi di distacco del sensore;
- **acc\_mag\_std:** deviazione standard della magnitudine; accettabile se  $< 10$  g, per escludere artefatti impulsivi di grande ampiezza.

Una finestra è classificata come valida ( $SQI = 1$ ) se e solo se tutte le condizioni sopra elencate sono simultaneamente soddisfatte. Le finestre con  $SQI = 0$  vengono escluse dall'addestramento e dalla valutazione del modello. La percentuale di finestre scartate per soggetto viene tracciata statisticamente al fine di quantificare la qualità complessiva del dataset.

## 2.4 Machine Learning per Segnali Fisiologici

### 2.4.1 Approccio a Finestre Temporali Scorrevoli

Il paradigma di analisi adottato è basato sulla segmentazione del segnale continuo in finestre temporali di ampiezza fissa con sovrapposizione parziale [15]. Ciascuna finestra di durata  $W = 30$  s con passo  $S = 15$  s (overlap del 50%) costituisce un'istanza del

dataset, caratterizzata dal vettore di feature estratte dai segnali ECG e accelerometrico. Il numero di finestre  $K$  ricavabili da un segnale di durata  $T$  è:

$$K = \left\lfloor \frac{T - W}{S} + 1 \right\rfloor = \left\lfloor \frac{T - 30}{15} + 1 \right\rfloor$$

L'overlap del 50% massimizza il numero di campioni disponibili e riduce la varianza della stima delle feature statistiche. La correlazione temporale tra finestre adiacenti che ne consegue è gestita attraverso la strategia di validazione incrociata descritta nella sezione dedicata.

## 2.4.2 Modelli di Classificazione

### Random Forest

Il Random Forest [12] è un metodo ensemble che costruisce  $B = 200$  alberi decisionali su sottocampioni bootstrap del dataset di addestramento, aggregando le predizioni tramite voto di maggioranza. Ogni albero considera, a ciascun nodo, un sottoinsieme casuale di  $\sqrt{p}$  feature (dove  $p$  è il numero totale di feature), riducendo la correlazione tra gli alberi e aumentando la stabilità dell'ensemble.

Il criterio di divisione dei nodi è l'impurità di Gini, definita per un nodo con  $K$  classi come:

$$G = \sum_{k=1}^K p_k(1 - p_k) = 1 - \sum_{k=1}^K p_k^2$$

dove  $p_k$  è la proporzione di campioni della classe  $k$  nel nodo. La divisione ottimale minimizza la somma pesata delle impurità dei nodi figli. Il parametro `class_weight='balanced'` adatta i pesi delle classi inversamente proporzionali alla loro frequenza:

$$w_k = \frac{N}{K \times N_k}$$

dove  $N$  è il numero totale di campioni e  $N_k$  è il numero di campioni della classe  $k$ , compensando automaticamente gli sbilanciamenti residui del dataset.

### Support Vector Machine

La SVM [13] determina l'iperpiano di separazione a massimo margine nello spazio delle feature trasformato mediante kernel. Il problema di ottimizzazione primale con margine morbido è:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i$$

soggetto a  $y_i(\mathbf{w}^T \varphi(\mathbf{x}_i) + b) \geq 1 - \xi_i$  con  $\xi_i \geq 0$ . Il parametro  $C$  regola il trade-off tra massimizzazione del margine e minimizzazione degli errori di classificazione. Per dataset con  $n < 10000$  campioni viene impiegato il kernel RBF (Radial Basis Function):

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$$

Per dataset con  $n \geq 10000$  campioni viene utilizzata la formulazione lineare (Linear-SVC), computazionalmente più efficiente nella gestione di grandi volumi di dati. I parametri  $C$  e  $\gamma$  sono ottimizzati mediante GridSearchCV.

### Regressione Logistica

La regressione logistica [15] stima la probabilità a posteriori della classe mediante la funzione sigmoide:

$$P(y = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

L'addestramento minimizza la funzione di perdita di cross-entropia con regolarizzazione L2:

$$L(\mathbf{w}) = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)] + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

dove  $\hat{p}_i = P(y = 1 \mid \mathbf{x}_i)$  e  $\lambda = 1/C$  è il coefficiente di regolarizzazione. Nel sistema, il solver `lbfgs` è configurato con `max_iter=1000` per garantire la convergenza su dataset di medie dimensioni.

### 2.4.3 SMOTE e Bilanciamento delle Classi

Lo sbilanciamento tra classi è un problema ricorrente nei dataset clinici, dove le classi patologiche sono tipicamente sottorappresentate rispetto ai soggetti sani [14]. Il metodo SMOTE (Synthetic Minority Over-sampling TEchnique) genera campioni sintetici della classe minoritaria attraverso interpolazione lineare nello spazio delle feature:

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda(\mathbf{x}_{\text{nn}} - \mathbf{x}_i), \quad \lambda \in [0, 1]$$

dove  $\mathbf{x}_i$  è un campione della classe minoritaria,  $\mathbf{x}_{\text{nn}}$  è uno dei suoi  $k$  nearest neighbors ( $k = 5$  per impostazione predefinita) nella stessa classe, e  $\lambda$  è un coefficiente campionato uniformemente. Rispetto al semplice oversampling con replicazione, SMOTE introduce diversità nel set sintetico riducendo il rischio di overfitting.

SMOTE è applicato **esclusivamente** all'interno della pipeline di cross-validazione, sui soli dati di addestramento di ciascun fold, e mai ai dati di validazione, per evitare qualsiasi forma di contaminazione tra partizioni.

#### 2.4.4 Metriche di Valutazione

La valutazione delle prestazioni dei classificatori si basa su un insieme di metriche complementari, necessarie per una corretta interpretazione in presenza di classi sbilanciate. A partire dalla matrice di confusione, che fornisce i conteggi di Veri Positivi (TP), Veri Negativi (TN), Falsi Positivi (FP) e Falsi Negativi (FN), si derivano:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad \text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad \text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$
$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \text{ TP}}{2 \text{ TP} + \text{FP} + \text{FN}}$$

Il Macro F1-score, metrica principale nelle valutazioni multi-classe, è la media aritmetica degli F1-score per ciascuna classe, assegnando peso uniforme a tutte indipendentemente dalla loro frequenza:

$$\text{Macro F1} = \frac{1}{K} \sum_{k=1}^K \text{F1}_k$$

L'area sotto la curva ROC (AUC-ROC) misura la capacità discriminativa del modello al variare della soglia di classificazione, con valore 0,5 per un classificatore casuale e 1,0 per un classificatore perfetto.

#### 2.4.5 Iperparametri e GridSearchCV

La selezione degli iperparametri ottimali è effettuata mediante GridSearchCV [15] con cross-validazione interna a 3 fold. Le griglie di ricerca adottate per i tre modelli sono le seguenti.

Per il **Random Forest**: numero di alberi  $B \in \{100, 200, 300\}$ , numero massimo di feature per nodo  $\text{max\_features} \in \{\text{sqrt}, \log 2\}$ , profondità massima degli alberi  $\text{max\_depth} \in \{10, 20, \text{None}\}$ .

Per la **SVM con kernel RBF**:  $C \in \{0, 1; 1; 10; 100\}$  e  $\gamma \in \{\text{scale}, \text{auto}, 0, 001, 0, 01\}$ .

Per la **Regressione Logistica**:  $C \in \{0, 01; 0, 1; 1; 10; 100\}$  con solver `lbfgs`.

La pipeline completa, implementata tramite `sklearn.pipeline.Pipeline` [15], è strutturata nei seguenti stadi applicati in sequenza:

1. **Imputer**: sostituzione dei valori mancanti (NaN) con la mediana della feature, stimatore robusto agli outlier;
2. **StandardScaler**: normalizzazione delle feature a media zero e varianza unitaria ( $z = \frac{x-\mu}{\sigma}$ ), necessaria per SVM e LR;
3. **SMOTE** (condizionale): applicato solo se il rapporto di sbilanciamento tra la classe maggioritaria e quella minoritaria supera il valore di 1,2;
4. **Classificatore**: uno dei tre modelli descritti nella sezione precedente.

L'intera pipeline è trattata come un singolo stimatore scikit-learn: le trasformazioni di preprocessing vengono apprese esclusivamente sui dati di addestramento di ciascun fold, garantendo che nessuna informazione proveniente dai dati di validazione influenzi i parametri di normalizzazione o di oversampling.

#### 2.4.6 Validazione Incrociata e Prevenzione del Data Leakage

Il data leakage rappresenta una delle principali insidie nella validazione dei modelli su dati fisiologici strutturati [15]. In presenza di finestre temporali con overlap estratte dallo stesso soggetto, uno split casuale delle finestre potrebbe assegnare finestre adiacenti — e quindi altamente correlate — a fold di addestramento e validazione diversi, producendo stime di prestazione eccessivamente ottimistiche non generalizzabili a nuovi pazienti.

Per prevenire questo problema, per l'obiettivo OBJ3 (stima della classe NY-HA) il sistema adotta la strategia **StratifiedGroupKFold**, in cui il parametro `groups=patient_id` garantisce che tutte le finestre appartenenti allo stesso soggetto siano sempre assegnate allo stesso fold, simulando un genuino scenario di generalizzazione a soggetti non visti. Per OBJ1 e OBJ2, dove il target (tipo di attività o REST/ACTIVITY) varia all'interno dello stesso paziente, è sufficiente la **StratifiedKFold** standard a 3 fold, che garantisce la rappresentatività delle classi senza vincoli inter-paziente.

La stratificazione preserva la proporzione delle classi approssimativamente costante tra i fold. Lo schema adottato prevede  $K_{\text{outer}} = 3$  fold esterni per la stima delle prestazioni e  $K_{\text{inner}} = 3$  fold interni per la selezione degli iperparametri tramite GridSearchCV, secondo lo schema di nested cross-validation, che produce stime di generalizzazione prive di bias da selezione del modello.

In sintesi, le basi teoriche presentate in questo capitolo — fisiologia dell'HRV, elaborazione del segnale accelerometrico, criteri di qualità SQI e fondamenti degli algoritmi ML — costituiscono il substrato concettuale necessario per la comprensione delle scelte implementative adottate nel sistema. I capitoli seguenti descrivono come questi elementi siano stati integrati in una pipeline coerente e ne presentano i risultati sperimentali.

## 3 Dataset e Metodi

### 3.1 Descrizione del Dataset

Il dataset utilizzato in questo lavoro è stato acquisito nell’ambito di un protocollo clinico di riabilitazione cardiaca post-chirurgica. I soggetti arruolati sono pazienti adulti sottoposti a intervento cardiocirurgico (bypass coronarico, valvuloplastica o sostituzione valvolare) e ammessi a un percorso riabilitativo strutturato. Per ogni paziente sono disponibili informazioni cliniche e demografiche: età, sesso, indice di massa corporea (BMI), punteggio EFS (*Elderly Fragility Score*), tipologia di intervento, giorni trascorsi dalla chirurgia, classe NYHA, presenza di fibrillazione atriale, BPCO (broncopneumopatia cronica ostruttiva), depressione, terapia con ACE inibitori e beta-bloccanti.

I dati fisiologici sono memorizzati in formato WFDB (*Waveform Database*), lo standard aperto adottato da PhysioNet per la distribuzione di segnali biomedici. Ogni sessione comprende due registrazioni sincronizzate:

- **ECG** monoderivazione, campionato a 130 Hz, acquisito mediante un dispositivo Holter indossabile posizionato sul torace.
- **Accelerometro** triassiale (assi X, Y, Z), campionato a 200 Hz, acquisito da un sensore MEMS indossabile al polso o alla cintura.

Ogni sessione è annotata con i marker di inizio di ciascun test clinico standardizzato, che costituiscono le etichette di attività (*test labels*):

| Etichetta     | Test clinico                                             |
|---------------|----------------------------------------------------------|
| STAIR         | Salita e discesa di una rampa di scale                   |
| 6MWT          | <i>6-Minute Walk Test</i> — cammino libero per 6 minuti  |
| TUG           | <i>Timed Up and Go</i> — alzarsi, camminare 3 m, tornare |
| VELO          | Cicloergometro a carico costante                         |
| GAIT_ANALYSIS | Analisi del cammino su piano                             |
| REST          | Riposo seduto/supino (pre-test, max 5 min)               |

**Tabella 3.1:** Test clinici registrati per ciascun paziente.

### 3.2 Pipeline di Pre-elaborazione

#### 3.2.1 Pre-elaborazione ECG

Il segnale ECG grezzo viene elaborato attraverso i seguenti passi:

1. **Filtraggio bandpass** con filtro Butterworth del 4° ordine, fase nulla (implementazione zero-phase tramite `sosfiltfilt`), banda passante 0,5–40 Hz. Il cut-off inferiore rimuove il *baseline wander* respiratorio; quello superiore limita il rumore ad alta frequenza e la componente di rete.
2. **Rilevazione dei picchi R** tramite l'algoritmo di Pan–Tompkins [9], con correzione degli artefatti integrata, implementato via NeuroKit2 [10].
3. **Calcolo degli intervalli R-R** in millisecondi come differenza tra sample consecutivi di picchi R, normalizzata per la frequenza di campionamento.
4. **Rejection adattivo degli outlier**: vengono eliminati tutti gli intervalli R-R al di fuori del range fisiologico [300, 2000] ms (corrispondenti a FC > 200 bpm e FC < 30 bpm, rispettivamente). Viene inoltre applicato un criterio adattivo: R-R a distanza superiore a 3 deviazioni standard dalla mediana locale vengono rimossi.

### 3.2.2 Pre-elaborazione Accelerometro

1. **Estrazione della componente gravitazionale** mediante filtro low-pass Butterworth (cut-off 0,3 Hz), applicato indipendentemente su ciascun asse.
2. **Accelerazione dinamica**: sottrazione della componente gravitazionale dal segnale grezzo, seguita da un filtraggio bandpass (0,3–20 Hz) per isolare i movimenti corporei e attenuare gli artefatti ad alta frequenza.
3. **Magnitudine vettoriale**:  $|a| = \sqrt{x_{\text{dyn}}^2 + y_{\text{dyn}}^2 + z_{\text{dyn}}^2}$ , invariante rispetto all'orientazione del sensore.

### 3.2.3 Segmentazione in Finestre Temporali

Ciascun segmento di test viene suddiviso in finestre temporali sovrapposte di durata fissa  $W = 30$  s con overlap del 50% (passo di 15 s). Il parametro di 30 s soddisfa il requisito di almeno 20 picchi R per le stime nel dominio temporale [5]. Per le stime nel dominio frequenziale (bande LF, HF), la Task Force raccomanda idealmente registrazioni  $\geq 5$  minuti; le finestre brevi di 30 s rappresentano un compromesso accettato nella letteratura sul monitoraggio real-time, con la consapevolezza che la risoluzione delle bande LF/VLF risulta ridotta.

### 3.2.4 Signal Quality Index (SQI)

Ogni finestra viene sottoposta a un controllo di qualità indipendente per ECG e ACC. Una finestra è *valida* solo se entrambi i segnali superano tutte le soglie:

| Metrica SQI          | Soglia | Interpretazione                                    |
|----------------------|--------|----------------------------------------------------|
| ecg_flatline_ratio   | < 5 %  | Frazione del segnale costante → distacco elettrodo |
| ecg_clip_ratio       | < 2 %  | Saturazione ADC → clipping                         |
| ecg_rr_quality_ratio | > 50 % | Frazione R-R sopravvissuti al cleaning             |
| ecg_cv_rr            | < 40 % | Coefficiente di variazione R-R → irregolarità      |
| ecg_n_rpeaks_clean   | ≥ 5    | Numero minimo picchi R per HRV                     |
| acc_flatline_ratio   | < 10 % | Sensore disconnesso o fermo                        |
| acc_clip_ratio       | < 2 %  | Saturazione del sensore MEMS                       |
| acc_magnitude_range  | > 5 mg | Minima dinamica del sensore                        |
| acc_magnitude_std    | < 10 g | Artefatto da movimento estremo                     |

**Tabella 3.2:** Soglie del Signal Quality Index per ECG e ACC.

L'applicazione del filtro SQI riduce il numero di finestre da circa 37.000 a **16.086 finestre valide**, corrispondente a un tasso di rigetto del 56,5%. La quota maggiore di rigetti è imputabile a finestre di riposo con ECG di bassa qualità (baseline wander elevato durante la deambulazione) e a finestre in cui il sensore accelerometrico risultava in uno stato quasi-stazionario (magnitudine < 5 mg, tipica di posture sedute protratte).

### 3.3 Estrazione delle Feature

Per ogni finestra valida vengono estratte feature in tre macro-gruppi, per un totale di 72 feature per gli obiettivi OBJ1 e OBJ2, estese a fino a 77 con l'aggiunta delle feature cliniche per OBJ3.

#### 3.3.1 Feature HRV (ECG)

Le 19 feature HRV sono calcolate dagli intervalli R-R della finestra secondo gli standard Task Force [5]:

**Dominio temporale** (7 indici): `mean_rr`, `sdnn`, `rmssd`, `pnn50`, `pnn20`, `hr_mean`, `cv_rr`. Lo SDNN stima la variabilità globale, l'RMSSD (e i relativi pNN50, pNN20) riflette la modulazione parasimpatica ad alta frequenza.

**Indici di Poincaré** (3 indici): `sd1`, `sd2`, `sd1_sd2_ratio`. SD1 cattura la variabilità battito-per-battito (parasimpatico); SD2 la variabilità a lungo termine (simpatico-vagale).

**Indice geometrico** (1 indice): `triangular_index` (HTI), rapporto tra numero totale di R-R e l'altezza del picco istogramma con bin  $1/128 \text{ s} \approx 7,8 \text{ ms}$ .

**Dominio frequenziale** (5 indici): `vlf_power`, `lf_power`, `hf_power`, `total_power`, `lf_hf_ratio`. Lo spettro è stimato con la trasformata di Lomb-Scargle [11] sul segnale



R-R campionato in modo non uniforme, coerentemente con le bande VLF (0,003–0,04 Hz), LF (0,04–0,15 Hz) e HF (0,15–0,40 Hz) definite dallo standard.

### 3.3.2 Feature Accelerometriche

Per ciascuno dei quattro canali (X, Y, Z e magnitudine) vengono estratte 9 feature statistiche e spettrali: `mean`, `std`, `energy`, `peak2peak`, `rms`, `dom_freq`, `spectral_energy`, `entropy`, `jerk_mean`. Completano il gruppo la *Signal Magnitude Area* (SMA) e le tre correlazioni inter-asse (`corr_xy`, `corr_xz`, `corr_yz`), per un totale di 40 feature ACC.

### 3.3.3 Feature Cliniche (solo OBJ3)

Per la stima della classe NYHA vengono aggiunte 5 feature cliniche anonimizzate: `age`, `gender`, `bmi`, `days_post_surgery`, `surgery_type`. Sono escluse deliberatamente le feature direttamente correlate con la classe NYHA (`efs`, `has_af`, `beta_blockers`) per evitare data leakage concettuale.

## 3.4 Classificatore ECG Rule-Based (Scenario B)

In aggiunta alle feature continue, è stato implementato un classificatore *rule-based* del ritmo cardiaco che assegna a ogni finestra una delle seguenti etichette discrete:

- **NORMAL**: frequenza cardiaca 60–100 bpm e  $CV\_RR < 20\%$ .
- **BRADY**:  $FC < 60$  bpm (*bradycardia*).
- **TACHY**:  $FC > 100$  bpm (*tachycardia*).
- **POSSIBLE\_AF**:  $CV\_RR \geq 20\%$  con FC nella norma (proxy di irregolarità compatibile con fibrillazione atriale).

Queste etichette costituiscono il cosiddetto *Scenario B* e possono essere utilizzate come feature aggiuntive o come variabile target per un obiettivo di classificazione del ritmo. Nel presente elaborato sono incluse nel dataset come feature categoriale codificata numericamente, ma la loro analisi approfondita è rimandata a sviluppi futuri.

## 3.5 Configurazione degli Esperimenti

### 3.5.1 Modelli di Classificazione

Per ciascun obiettivo vengono addestrati e confrontati tre classificatori:

- **Random Forest** (RF): 200 alberi decisionali, bilanciamento delle classi tramite pesatura inversamente proporzionale alla frequenza (`class_weight="balanced"`), parallelizzazione su tutti i core disponibili.

- **Support Vector Machine (SVM)**: kernel RBF per dataset di dimensione inferiore a 10.000 campioni; sostituito con LinearSVC per dataset più grandi, per ragioni di efficienza computazionale.
- **Logistic Regression (LR)**: regolarizzazione L2, `max_iter=1000`.

Tutti i modelli sono incapsulati in una pipeline scikit-learn [15] che include: (1) imputazione dei valori mancanti con la mediana della colonna, (2) standardizzazione Z-score, (3) opzionalmente SMOTE per il bilanciamento del training set, (4) il classificatore. L'intera pipeline fa uso delle librerie NumPy [16], pandas [17] e SciPy [18] per la manipolazione dei dati e il filtraggio digitale. La ricerca degli iperparametri ottimali è condotta tramite GridSearchCV con 3-fold inner CV.

### 3.5.2 Strategia di Validazione

La scelta della strategia di cross-validazione dipende dalla natura della variabile target:

**OBJ1 e OBJ2** — Il target (tipo di attività o REST/ACTIVITY) varia *all'interno* dello stesso paziente: la stessa persona esegue test diversi. È quindi corretto utilizzare una **StratifiedKFold a 3 fold**, che garantisce la rappresentatività delle classi in ogni fold senza vincoli a livello paziente.

**OBJ3** — Il target (classe NYHA) è una proprietà *del paziente*: tutte le finestre di un dato paziente hanno la stessa classe. Se le finestre dello stesso paziente comparissero sia nel training che nel test set, il modello potrebbe «memorizzare» pattern individuali anziché generalizzare. Per prevenire questo **data leakage**, OBJ3 utilizza **StratifiedGroupKFold a 3 fold** con `groups = patient_id`: nessun paziente può apparire contemporaneamente nel training e nel test set.

### 3.5.3 Metriche di Valutazione

I risultati sono valutati tramite le seguenti metriche, calcolate con `cross_val_predict` sull'intera popolazione di finestre:

- **F1-score macro-pesato** (`f1_weighted`): media pesata per il supporto di classe, robusta allo sbilanciamento.
- **Accuratezza** (`accuracy`): percentuale di predizioni corrette.
- **AUC-ROC**: area sotto la curva ROC in schema one-vs-rest per i problemi multi-classe.
- **Matrice di confusione**: analisi degli errori tra classi adiacenti.
- **Feature importance**: analisi degli indici di Gini (per RF) per identificare quali feature guidano maggiormente la classificazione.

## 3.6 Architettura del Sistema Wearable

La pipeline sviluppata in questa tesi è progettata secondo un'architettura a due livelli — **edge** e **cloud** — coerente con i vincoli energetici e computazionali dei dispositivi indossabili e con i requisiti di latenza delle applicazioni cliniche in tempo reale [4].

### 3.6.1 Livello Edge (dispositivo indossabile)

Il livello edge è eseguito direttamente sul microcontrollore del dispositivo wearable (es. ARM Cortex-M4 a basso consumo). Comprende le operazioni che devono avvenire localmente per minimizzare la trasmissione di dati grezzi e consentire un feedback immediato:

1. **Pre-elaborazione del segnale:** filtraggio Butterworth passa-banda dell'ECG (0,5–40 Hz, ordine 4) e rimozione della componente gravitazionale dall'accelerometro (passa-basso 0,3 Hz + passa-banda 0,3–20 Hz). Calcolo dell'indice SQI per scartare finestre di scarsa qualità.
2. **Estrazione delle feature:** calcolo degli intervalli R-R e delle feature HRV di base (HR, SDNN, RMSSD, pNN50), delle feature ACC nel dominio del tempo (media, RMS, jerk, SMA) e della frequenza dominante. Il vettore risultante è compresso rispetto al segnale grezzo di un fattore  $500\times$ .
3. **Classificazione rule-based:** decisioni deterministiche a bassa latenza basate su soglie cliniche consolidate:
  - **Bradycardia:**  $HR < 60$  bpm
  - **Tachicardia:**  $HR > 100$  bpm
  - **Pausa:**  $\text{gap R-R} > 2,5$  s
  - **POSSIBLE\_AF:**  $CV(RR) > 20\%$ ,  $RMSSD > 50$  ms,  $pNN50 > 20\%$ ,  $SD1 > 35$  ms
4. **Classificazione ML leggera:** modelli Random Forest ridotti (profondità limitata) per i task binari a bassa complessità: REST vs ACTIVITY (OBJ2) e rilevamento di aritmie semplici. Questi modelli sono aggiornabili via OTA (*over-the-air update*) dal livello cloud.

### 3.6.2 Livello Cloud

Il livello cloud riceve il vettore di feature compresso tramite BLE o LPWAN (Low-Power Wide-Area Network) e svolge le analisi che richiedono maggiore potenza computazionale o contesto longitudinale:

1. **Analisi avanzata:** classificazione del tipo di attività motoria (OBJ1, 5 classi), stima della classe NYHA (OBJ3) e analisi di correlazione  $ACC \leftrightarrow HRV$  con regressione OLS multi-feature.

2. **Anomaly detection e trend clinico:** rilevamento di derive del segmento ST/T (sospetta ischemia) tramite change-point detection e monitoraggio longitudinale dei parametri HRV nel corso del percorso riabilitativo.
3. **Alert multilivello:** aggregazione delle evidenze provenienti dal livello rule-based (edge) e dai classificatori ML (cloud) in un sistema di allerta probabilistico: priorità ALTA (aritmia rilevata sull'edge), MEDIA (anomalia HRV rilevata sul cloud), BASSA (trend peggiorativo longitudinale).
4. **Aggiornamento dei modelli:** i modelli ML vengono riaddestrati periodicamente con nuovi dati annotati e ridistribuiti al dispositivo edge tramite aggiornamento OTA, realizzando un ciclo di apprendimento continuo.

| Layer | Operazioni                             | Metodo                          |
|-------|----------------------------------------|---------------------------------|
| Edge  | Pre-elaborazione, SQI, R-peak          | Butterworth, Pan-Tompkins       |
| Edge  | Feature extraction (base)              | HRV time-domain, ACC tempo/freq |
| Edge  | Classificazione Brady/Tachy/AF         | Rule-based (soglie cliniche)    |
| Edge  | Classificazione REST vs ACTIVITY       | Random Forest leggero           |
| Cloud | Stima NYHA, tipo attività              | Random Forest completo (OBJ1/3) |
| Cloud | Correlazione ACC $\leftrightarrow$ HRV | Pearson, Spearman, OLS          |
| Cloud | Anomaly detection ST/T                 | Change-point, trend analysis    |
| Cloud | Alert clinico multilivello             | Aggregazione probabilistica     |

**Tabella 3.3:** Distribuzione delle operazioni tra livello edge e livello cloud.

La suddivisione proposta tra operazioni edge e cloud, riassunta nella Tabella 3.3, rispecchia le attuali linee guida per sistemi IoT clinici. I risultati ottenuti suggeriscono che la pipeline proposta non si limita al contesto sperimentale analizzato, ma risulta generalizzabile a sistemi wearable reali, in cui sensori accelerometrici ed ECG a bassa complessità possono essere integrati per il monitoraggio continuo dello stato cardiaco e motorio del paziente. Questa caratteristica rende l'approccio particolarmente adatto a scenari di telemedicina e riabilitazione domiciliare, dove è necessario un sistema scalabile, non invasivo e a basso costo.

## 4 Analisi della Correlazione ACC ↔ HRV

Uno degli obiettivi principali di questa tesi è verificare se le feature estratte dall'accelerometro indossabile siano statisticamente correlate con i parametri di variabilità della frequenza cardiaca (HRV). Questa analisi costituisce il fondamento teorico che giustifica l'utilizzo dell'ACC come surrogato non-invasivo dello stato cardiaco del paziente.

### 4.1 Metodologia Statistica

Per quantificare il legame tra ogni feature ACC e il parametro HRV target (intervallo R-R medio, espresso in ms) sono stati applicati tre approcci complementari:

#### 4.1.1 Correlazione di Pearson

Per ogni coppia (feature<sub>ACC</sub>, RR<sub>medio</sub>) è stato calcolato il coefficiente di correlazione di Pearson  $r$ , definito come:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

dove  $x_i$  è il valore della feature ACC e  $y_i$  è il corrispondente valore di RR medio nella finestra temporale  $i$ . Il test è stato effettuato su tutte le  $n = 16.086$  finestre valide (superate il filtro SQI). La significatività statistica è stata fissata a  $p < 0.05$  con correzione di Bonferroni per confronti multipli.

#### 4.1.2 Regressione Lineare Semplice (OLS)

Per le feature con correlazione significativa è stato stimato un modello di regressione lineare ordinaria (OLS):

$$\text{RR}_{\text{medio}} = \beta_0 + \beta_1 \cdot x + \varepsilon$$

Il coefficiente di determinazione  $R^2$  indica la frazione di varianza dell'RR medio spiegata dalla singola feature ACC. Valori di  $p$ -value per il test  $F$  inferiori a 0.05 confermano la significatività del modello.

#### 4.1.3 Correlazione di Spearman

In aggiunta alla correlazione di Pearson, è stato calcolato il coefficiente di correlazione per ranghi di Spearman  $\rho$ , definito come la correlazione di Pearson applicata ai ranghi delle variabili:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

dove  $d_i$  è la differenza tra i ranghi di  $x_i$  e  $y_i$ . Lo Spearman è robusto rispetto a relazioni monotone non lineari e a distribuzioni non normali, tipiche di segnali fisiologici reali. Il confronto tra  $r$  (Pearson) e  $\rho$  (Spearman) consente di valutare se la relazione ACC–HRV abbia natura prevalentemente lineare o monotona più generale.

## 4.2 Risultati delle Correlazioni

### 4.2.1 Top Feature a livello globale

La Tabella 4.1 riporta le dieci feature ACC con maggiore correlazione (in valore assoluto) con l'intervallo R-R medio, calcolate sull'intero dataset.

| Feature ACC             | r Pearson | $\rho$ Spearman | R <sup>2</sup> | p-value                |
|-------------------------|-----------|-----------------|----------------|------------------------|
| acc_mag_dom_freq        | −0.298    | −0.320          | 0.089          | $\approx 0$            |
| acc_mag_jerk_mean       | −0.217    | −0.241          | 0.047          | $5.0 \times 10^{-170}$ |
| acc_z_jerk_mean         | −0.203    | −0.211          | 0.041          | $5.8 \times 10^{-149}$ |
| acc_x_jerk_mean         | −0.201    | −0.191          | 0.041          | $8.5 \times 10^{-147}$ |
| acc_z_spectral_energy   | −0.179    | −0.196          | 0.032          | $2.5 \times 10^{-116}$ |
| acc_mag_spectral_energy | −0.162    | −0.170          | 0.026          | $3.3 \times 10^{-95}$  |
| acc_max_intercorr       | +0.155    | +0.168          | 0.024          | $1.4 \times 10^{-87}$  |
| acc_mag_energy          | −0.155    | −0.184          | 0.024          | $3.6 \times 10^{-87}$  |
| acc_x_entropy           | −0.155    | −0.160          | 0.024          | $4.7 \times 10^{-87}$  |
| acc_mag_mean            | −0.151    | −0.195          | 0.023          | $5.1 \times 10^{-83}$  |

**Tabella 4.1:** Top 10 feature ACC più correlate con l'intervallo RR medio, calcolate sull'intero dataset ( $n = 16.086$  finestre valide).

La feature più correlata è la **frequenza dominante della magnitudine dell'accelerazione** (acc\_mag\_dom\_freq), con  $r_{\text{Pearson}} = -0.298$  e  $\rho_{\text{Spearman}} = -0.320$  ( $R^2 = 0.089$ ). I due coefficienti sono molto prossimi, indicando che la relazione è prevalentemente lineare. Il segno negativo indica che all'aumentare della frequenza di movimento (più passi al secondo) corrisponde una diminuzione dell'intervallo R-R (cioè un aumento della frequenza cardiaca), coerentemente con la fisiologia dell'esercizio.

Il **jerk medio** (derivata prima dell'accelerazione) nelle direzioni  $z$  e  $x$  occupa le posizioni 2–4, confermando che la variazione rapida del movimento è un predittore affidabile del carico cardiaco.

Tutti i  $p$ -value sono trascurabili (molti effettivamente pari a zero in precisione numerica doppia), a conferma che le correlazioni non sono spurie.

#### 4.2.2 Analisi per Tipo di Attività

Le correlazioni variano sensibilmente in funzione del test motorio eseguito. La Tabella 4.2 mostra la feature più correlata con l'RR medio per ciascuna attività del protocollo:

| Attività              | Feature migliore  | r      | p-value                |
|-----------------------|-------------------|--------|------------------------|
| 6MWT (cammino 6 min)  | acc_mag_jerk_mean | -0.296 | $1.5 \times 10^{-114}$ |
| TUG (timed up-and-go) | acc_x_entropy     | -0.410 | $4.7 \times 10^{-72}$  |
| GAIT analysis         | acc_mag_dom_freq  | -0.496 | $9.9 \times 10^{-263}$ |
| STAIR (scale)         | acc_x_jerk_mean   | -0.242 | $1.5 \times 10^{-32}$  |
| VELO (cicloergometro) | acc_mag_jerk_mean | -0.347 | $2.1 \times 10^{-36}$  |
| REST (riposo)         | acc_mag_jerk_mean | -0.294 | $1.6 \times 10^{-18}$  |


**Tabella 4.2:** Feature ACC più correlata con RR medio per tipo di attività e per il periodo di riposo (REST).

Il TUG mostra la correlazione più alta ( $|r| = 0.410$ ) usando l'entropia dell'asse  $x$ : questo test richiede transizioni posturali (alzarsi, girare, sedersi) che si riflettono sia nell'irregolarità del movimento che nella risposta cardiaca autonoma. La GAIT analysis presenta invece la correlazione più alta con `acc_mag_dom_freq` ( $|r| = 0.496$ ), perché durante il cammino libero la cadenza dei passi è il principale determinante del carico cardiaco.

Il periodo di **REST** (riposo pre-test, 858 finestre valide) mostra una correlazione significativa con `acc_mag_jerk_mean` ( $r = -0.294$ ,  $p = 1.6 \times 10^{-18}$ ), simile in modulo a quella osservata durante il cammino. Questo risultato è fisiologicamente coerente: anche in condizioni di quiete motoria, i micromovimenti residui (aggiustamenti posturali, respiro) correlano negativamente con l'intervallo R-R. Una mancata variazione dell'R-R in risposta alla quiete motoria — ovvero un R-R che non aumenta come atteso — costituisce il marcatore fisiologico di alterazione autonoma che motiva l'obiettivo OBJ3 (stima della classe NYHA).


#### 4.2.3 Visualizzazioni

La Figura 4.1 mostra la matrice di correlazione tra le feature ACC selezionate e i principali parametri HRV.



**Figura 4.1:** Heatmap delle correlazioni ACC–HRV (Pearson  $r$ ).

Lo scatter plot in Figura 4.2 illustra la relazione tra la SMA (Signal Magnitude Area) e l'RR medio con la retta di regressione OLS sovrapposta.



**Figura 4.2:** Scatter plot: SMA vs RR medio, retta OLS, colore per attività.



## 4.3 Interpretazione Clinica

I risultati evidenziano tre messaggi chiave:

### 1. Le feature cinematiche dominano.

La frequenza dominante e il jerk catturano meglio l'intensità del movimento rispetto a feature statiche (media, RMS). Questo è coerente con la letteratura sull'HRV da esercizio, dove la modulazione autonoma risponde alla dinamica del carico più che al suo valore assoluto istantaneo.

### 2. $L'R^2$ massimo è limitato ( 9%).

Nessuna singola feature ACC spiega più del 9% della varianza dell'RR medio nel modello OLS. La concordanza tra  $r$  (Pearson) e  $\rho$  (Spearman) in tutta la tabella indica che le relazioni sono prevalentemente lineari, non solo monotone: il modello lineare è quindi appropriato. Tuttavia, esistono altri fattori (stato autonomo basale, farmaci, gravità della patologia NYHA) che influenzano l'HRV indipendentemente dal movimento. Per questa ragione il capitolo successivo adotta un approccio multi-feature con classificatori ML invece di un semplice modello lineare.

### 3. La feature ottimale dipende dall'attività.

Non esiste un'unica feature ACC universale: il predittore migliore cambia in funzione del tipo di test (cadenza per GAIT, irregolarità per TUG). Questo suggerisce che i modelli di classificazione beneficino di un insieme eterogeneo di feature piuttosto che di un sottoinsieme pre-selezionato.

In sintesi, l'analisi di correlazione conferma la plausibilità fisiologica dell'approccio proposto: i segnali ACC contengono informazione rilevante sullo stato cardiaco del paziente, fornendo una base solida per la classificazione ML presentata nel capitolo seguente.

## 5 Classificazione Automatica

Questo capitolo presenta i risultati della classificazione automatica per i tre obiettivi del progetto. Tutti i modelli sono stati addestrati e valutati seguendo la pipeline descritta nel Capitolo 3: imputazione, standardizzazione Z-score, opzionalmente SMOTE, Grid-SearchCV con 3-fold inner CV, e cross-validazione esterna con strategia adeguata alla natura del target.

La Tabella 5.1 riassume le metriche principali per i tre obiettivi.

| Obiettivo               | Modello             | Accuratezza | F1 pesato | F1 macro |
|-------------------------|---------------------|-------------|-----------|----------|
| OBJ1 — Attività (5 cl.) | Random Forest       | 78,9 %      | 0,782     | 0,750    |
| OBJ1 — Attività (5 cl.) | SVM (LinearSVC)     | 41,6 %      | 0,424     | 0,376    |
| OBJ1 — Attività (5 cl.) | Logistic Regression | 37,5 %      | 0,388     | 0,358    |
| OBJ2 — REST/ACT (bin.)  | Random Forest       | 95,2 %      | 0,933     | 0,577    |
| OBJ2 — REST/ACT (bin.)  | SVM (LinearSVC)     | 63,1 %      | 0,732     | 0,460    |
| OBJ2 — REST/ACT (bin.)  | Logistic Regression | 63,5 %      | 0,734     | 0,461    |
| OBJ3 — NYHA (4 cl.)     | Random Forest       | 70,0 %      | 0,590     | 0,206    |
| OBJ3 — NYHA (4 cl.)     | SVM (LinearSVC)     | 53,2 %      | 0,547     | 0,246    |
| OBJ3 — NYHA (4 cl.)     | Logistic Regression | 51,4 %      | 0,535     | 0,244    |


**Tabella 5.1:** Riepilogo dei risultati di classificazione per i tre obiettivi.

### 5.1 OBJ1 — Tipo di Attività Motoria (5 Classi)

L'obiettivo OBJ1 consiste nel classificare automaticamente il tipo di test motorio in corso a partire dalle feature estratte dalle finestre di 30 s: cinque classi target — 6MWT, GAIT\_ANALYSIS, STAIR, TUG, VELO. Il training set comprende 15.228 finestre valide (le 858 finestre senza etichetta di test sono escluse); la validazione è condotta con StratifiedKFold a 3 fold.

### 5.1.1 Risultati

Il Random Forest raggiunge un F1-score pesato di **0,782** e un'accuratezza dell'**78,9 %**, superando nettamente SVM ( $F1 = 0,424$ ) e Logistic Regression ( $F1 = 0,388$ ). Il divario è attribuibile alla capacità del RF di catturare relazioni non lineari tra feature e alla sua robustezza in presenza di feature eterogenee (feature temporali, spettrali e HRV con scale molto diverse).



**Figura 5.1:** Matrice di confusione normalizzata — OBJ1, Random Forest.

La matrice di confusione in Figura 5.1 rivela che gli errori principali avvengono tra classi cinematicamente simili:

- **6MWT ↔ GAIT\_ANALYSIS**: entrambi i test consistono in cammino piano; la distinzione risiede nella durata (6 min vs analisi breve) e nella cadenza imposta, che le feature spettrali catturano parzialmente ma non in modo perfetto.
- **STAIR ↔ TUG**: entrambi implicano transizioni posturali (alzarsi, scale) con profili di accelerazione verticale simili.

Il test **VELO** (cicloergometro) è quello meglio classificato: la frequenza di pedalata imprime un pattern spettrale caratteristico (`acc_mag_dom_freq` picca a 1–2 Hz) che lo distingue chiaramente dagli altri test.

### 5.1.2 Confronto dei Modelli

Il degrado di SVM e Logistic Regression rispetto al RF ha una doppia spiegazione:

1. **Non linearità:** la frontiera di decisione tra classi attività non è linearmente separabile nello spazio delle 72 feature. Il RF, costruendo combinazioni di soglie su feature diverse, approssima meglio questa frontiera.
2. **Dimensione del dataset:** per  $n > 10.000$ , LinearSVC (usato al posto di RBF-SVM per efficienza) perde la capacità di adattarsi a relazioni curve, mentre RF non soffre di questa limitazione.


## 5.2 OBJ2 — Distinzione REST vs ACTIVITY

L'obiettivo OBJ2 è un classificatore binario che distingue le finestre di riposo (REST, classe 0) dalle finestre di qualsiasi attività motoria (classe 1). Questo task serve da *sanity check* del sistema: se il segnale wearable non fosse in grado di distinguere riposo da attività, non avrebbe senso procedere con gli obiettivi più ambiziosi.

Il dataset OBJ2 comprende tutte le 16.086 finestre valide; la validazione è StratifiedKFold a 3 fold.

### 5.2.1 Risultati

Il Random Forest raggiunge **F1 pesato = 0,933** e accuratezza **95,2 %**, un risultato eccellente che conferma la discriminatività del segnale accelerometrico. L'F1 macro (0,577), sensibilmente inferiore, riflette lo sbilanciamento del dataset: le finestre REST sono una minoranza rispetto alle finestre di attività, e il modello ottimizza prevalentemente la classe maggioritaria.



**Figura 5.2:** Matrice di confusione — OBJ2, Random Forest.

Dalla Figura 5.2 si osserva che il modello classifica correttamente la quasi totalità delle finestre di attività, mentre commette qualche falso negativo sulla classe REST (finestre

di riposo classificate come attività). Questo è un comportamento atteso in presenza di sbilanciamento e non costituisce un limite critico per l'applicazione: nella pratica clinica, una falsa classificazione «attività» di una finestra di riposo è meno grave della situazione inversa.

Il risultato di OBJ2 ha anche un'implicazione metodologica: poiché accuratezza e F1 pesato sono elevati, le feature estratte hanno un contenuto informativo sufficiente a supportare task di classificazione più difficili come OBJ1 e OBJ3.

### 5.3 OBJ3 — Stima dello Stato Clinico NYHA

OBJ3 è l'obiettivo più ambizioso e clinicamente rilevante: stimare la classe NYHA del paziente (I, II, III, IV) a partire dalle feature wearable. Questo task è strutturalmente più difficile degli altri per due ragioni:

1. **Etichetta a livello paziente:** la classe NYHA è costante per tutte le finestre di uno stesso paziente (non varia tra test diversi dello stesso soggetto). Il numero effettivo di campioni indipendenti è quindi il numero di *pazienti*, non il numero di *finestre*.
2. **Confondenti biologici:** l'HRV e il pattern motorio di un paziente NYHA II possono sovrapporsi con quelli di un paziente NYHA I in certi contesti, perché la classe NYHA cattura la limitazione *soggettiva* percepita, non solo parametri oggettivi.

#### 5.3.1 Configurazione Sperimentale


Per OBJ3 sono state eseguite tre varianti sperimentali:

- **OBJ3a** — 4 classi NYHA I–IV con SMOTE (15.587 finestre, StratifiedGroupKFold).
- **OBJ3b** — classificazione binaria  $\text{NYHA} \leq \text{II}$  vs  $\text{NYHA} \geq \text{III}$  con SMOTE (discretizzazione clinicamente motivata: NYHA I–II = impairment lieve; NYHA III–IV = impairment severo).
- **OBJ3c** — aggregazione a livello paziente (media delle feature HRV per paziente) con Leave-One-Out Cross-Validation (LOOCV). Il numero di campioni è ridotto al numero di pazienti unici, eliminando completamente il data leakage inter-finestra.

I risultati riportati nella Tabella 5.1 si riferiscono a OBJ3a (4 classi, livello finestra con group-aware CV).

#### 5.3.2 Risultati e Interpretazione

Il Random Forest su OBJ3a raggiunge F1 pesato = **0,590** e accuratezza = **70,0 %**. L'F1 macro è molto basso (0,206), indicando che il modello fatica con le classi rare (NYHA IV in particolare).



**Figura 5.3:** Matrice di confusione — OBJ3a (4 classi NYHA), Random Forest con StratifiedGroupKFold.

Dalla Figura 5.3 emergono due pattern:

- Le classi **NYHA I e II** sono confuse frequentemente tra loro: la differenza tra un paziente con lieve limitazione e uno senza limitazione è spesso non rilevabile dal segnale wearable.
- La classe **NYHA IV** è quasi sempre misclassificata come NYHA III: la scarsità di esempi (pochi pazienti con insufficienza cardiaca avanzata che eseguono test motori) rende questa classe difficile da generalizzare.


La variante binaria OBJ3b ( $\text{NYHA} \leq \text{II}$  vs  $\geq \text{III}$ ) produce un F1 pesato superiore (0,65 sul dataset di validazione), confermando che il segnale wearable contiene informazione discriminativa sulla gravità complessiva, anche se non riesce a distinguere le sfumature tra classi adiacenti.

### 5.3.3 Confronto con la Letteratura

I risultati di OBJ3 sono coerenti con la letteratura recente sulla stima automatica della classe NYHA da segnali wearable. [5] documenta l'alta variabilità inter-individuale dell'HRV anche all'interno della stessa classe NYHA. Studi recenti [4] riportano accuratezze simili (60–70 %) su task analoghi con dataset comparabili, suggerendo che il limite non è nella pipeline di classificazione ma nella natura intrinsecamente soggettiva dell'etichetta NYHA.

## 5.4 Analisi della Feature Importance


La Figura 5.4 mostra l'importanza relativa delle feature per il classificatore Random Forest su OBJ1 (tipo di attività).



**Figura 5.4:** Feature importance (indice di Gini) — OBJ1, Random Forest.

Le feature con importanza più elevata per OBJ1 sono:


1. **acc\_mag\_dom\_freq** — frequenza dominante della magnitudine: cattura la cadenza del movimento, diversa per ogni tipo di test (pedalata, cammino, scale).
2. **acc\_mag\_spectral\_energy** e **acc\_z\_spectral\_energy** — energia spettrale sull'asse verticale: discrimina test con componente verticale intensa (scale) da test orizzontali (cammino, cicloergometro).
3. **acc\_mag\_jerk\_mean** — variazione rapida del movimento: alta durante TUG e STAIR, bassa durante il cammino continuo.
4. **Feature HRV** (ecg\_mean\_rr, ecg\_sdn) — compaiono nelle posizioni medio-alte, confermando che la risposta cardiaca contribuisce alla distinzione tra test di diversa intensità.



**Figura 5.5:** Feature importance (indice di Gini) — OBJ2 (REST vs ACTIVITY), classificatore Random Forest.

Per OBJ2 (Figura 5.5), le feature di energia e magnitudine dell'ACC dominano nettamente: la distinzione riposo/attività è essenzialmente un problema di *livello* di movimento. Le feature HRV (`ecg_mean_rr`, `ecg_hr_mean`) compaiono tra le prime 10, confermando che anche la risposta cardiaca discrimina riposo da sforzo.






**Figura 5.6:** Feature importance — OBJ3b (NYHA binario), Random Forest.

Per OBJ3b (Figura 5.6), le feature HRV salgono in importanza: SDNN, RMSSD e il rapporto LF/HF — che riflettono il tono autonomico del paziente — sono tra i predittori più informativi. Questo è coerente con la letteratura clinica che associa HRV ridotta a classe NYHA più severa. Le feature accelerometriche compaiono anch’esse, suggerendo che il profilo di movimento del paziente (intensità, velocità, irregolarità) porta informazione aggiuntiva sulla sua condizione funzionale.

## 5.5 Confronto Sintetico dei Modelli



**Figura 5.7:** Confronto dell’F1-score pesato per tutti i modelli e obiettivi.

La Figura 5.7 sintetizza le prestazioni dei tre classificatori su tutti gli obiettivi. Il Random Forest è consistentemente superiore su tutti i task, in misura tanto più marcata quanto più il task richiede la cattura di relazioni non lineari (OBJ1, OBJ3). Per OBJ2 il vantaggio è meno pronunciato in F1 macro perché lo sbilanciamento penalizza tutti i modelli sulla classe minoritaria (REST).

## 5.6 Limiti Sperimentali

Alcuni fattori limitano la generalizzabilità dei risultati e devono essere considerati nell’interpretazione:

**Dimensione del campione.** Il dataset comprende un numero relativamente limitato di *pazienti* unici (dell’ordine delle decine), anche se le finestre temporali sono 16.086. Per OBJ3, dove ogni paziente è un campione indipendente, questo si traduce in una stima della generalizzazione ad alta varianza. Un dataset con un maggior numero di pazienti — specialmente nelle classi NYHA III e IV — consentirebbe stime più robuste.

**Sbilanciamento delle classi.** Le classi NYHA III e IV sono sotto-rappresentate rispetto a NYHA I e II nella popolazione riabilitativa (i pazienti più gravi eseguono meno test completi). Nonostante SMOTE e la pesatura delle classi, questo sbilanciamento riduce la recall sulle classi rare.

**Singola derivazione ECG.** L’ECG acquisito è monoderivazione: questo limita la capacità di rilevare pattern morfologici complessi (morfologia del QRS, sottoslivellamento ST) che potrebbero migliorare OBJ3. La pipeline è stata progettata per essere compatibile con derivazioni aggiuntive come sviluppo futuro.

**Eterogeneità dei protocolli.** Le sessioni di test non sono tutte condotte nelle stesse condizioni (ora del giorno, tempo trascorso dall'intervento, presenza di stimolazione atriale). Queste variabili confondenti non sono tutte disponibili nei metadati e non sono quindi controllate.

**Assenza di validazione esterna.** I risultati sono stati ottenuti su cross-validazione intra-dataset. Una validazione su un dataset esterno indipendente — con pazienti acquisiti in un diverso centro clinico — è necessaria per certificare la generalizzabilità del sistema.

Nonostante questi limiti, il quadro complessivo indica che la pipeline proposta raggiunge risultati coerenti con lo stato dell'arte per task analoghi nella letteratura sul monitoraggio wearable cardiaco, ottenuti su un dataset reale con le difficoltà intrinseche di segnali clinici non controllati. Il capitolo seguente integra questi risultati in una sintesi conclusiva e discute le implicazioni pratiche per il monitoraggio della riabilitazione cardiaca.

## 6 Conclusioni e Sviluppi Futuri

### 6.1 Sintesi dei Risultati

Il presente elaborato ha sviluppato e validato una pipeline end-to-end per l'analisi automatica di segnali fisiologici acquisiti da dispositivi indossabili in pazienti sottoposti a riabilitazione cardiaca post-chirurgica. La pipeline integra pre-elaborazione del segnale ECG e accelerometrico, filtraggio della qualità (SQI), estrazione di 72 feature, analisi di correlazione statistica e classificazione multi-obiettivo con tre algoritmi di machine learning.

I risultati principali si riassumono come segue:

**Correlazione ACC↔HRV (obiettivo trasversale).** L'analisi di correlazione ha dimostrato l'esistenza di una relazione statistica significativa tra le feature accelerometriche e i parametri HRV su tutte le 16.086 finestre valide. La frequenza dominante della magnitudine (`acc_mag_dom_freq`) è il predittore migliore dell'intervallo R-R medio ( $r = -0.298$ ,  $\rho = -0.320$ ,  $p \approx 0$ ). Il segno negativo — aumento della cadenza di movimento corrisponde a diminuzione dell'RR, ovvero aumento della FC — è fisiologicamente coerente con la risposta simpatica all'esercizio. L' $R^2$  massimo di una singola feature (9 %) indica che la relazione è reale ma moderata, richiedendo un approccio multi-feature per la classificazione.

**OBJ1 — Tipo di attività motoria.** Il Random Forest raggiunge un F1 pesato di **0,782**, confermando che i segnali wearable discriminano efficacemente i cinque test del protocollo riabilitativo. Gli errori si concentrano tra coppie di test cinematicamente simili (cammino libero vs analisi del cammino; TUG vs scale), un risultato atteso e accettabile nella pratica clinica.

**OBJ2 — REST vs ACTIVITY.** Con un F1 pesato di **0,933** e accuratezza del 95,2 %, il classificatore binario dimostra che anche con un singolo sensore ACC indossabile è possibile distinguere automaticamente le fasi di riposo da quelle di attività motoria. Questo risultato costituisce la prova di concetto che motiva l'intero approccio wearable.

**OBJ3 — Stima della classe NYHA.** L'F1 pesato di **0,590** con validazione patient-aware (StratifiedGroupKFold, nessun paziente nel training e test contemporaneamente) rappresenta un risultato confrontabile con la letteratura. La variante binaria ( $NYHA \leq II$  vs  $\geq III$ ) produce F1 più elevato, suggerendo che il segnale wearable cattura la distinzione grossolana tra limitazione lieve e severa, ma non le sfumature tra classi adiacenti.

La feature importance mostra coerenza con la fisiologia dell'esercizio: per OBJ1 dominano le feature spettrali e cinematiche dell'ACC; per OBJ3 emergono le feature

HRV (SDNN, RMSSD, LF/HF), a conferma del legame tra variabilità cardiaca e stato clinico.

## 6.2 Implicazioni Cliniche

I risultati ottenuti suggeriscono che una possibile architettura applicativa del sistema prevede una suddivisione tra elaborazione locale (edge) e analisi centralizzata (cloud). In particolare, il preprocessing del segnale e il calcolo delle feature possono essere eseguiti direttamente sul dispositivo wearable, mentre i modelli di classificazione e l'analisi longitudinale possono essere demandati a un'infrastruttura remota.

I risultati di questo lavoro aprono prospettive concrete per il monitoraggio continuo nella riabilitazione cardiaca:

**Monitoraggio oggettivo e continuo.** La scala NYHA è attualmente valutata *spot* durante la visita, con inevitabile soggettività. Un sistema in grado di stimare la classe NYHA — anche con accuratezza limitata — tra una visita e l'altra, attraverso i dati di un dispositivo indossabile, fornirebbe al clinico un'informazione *longitudinale* preziosa: l'andamento della risposta autonoma durante i test riabilitativi può segnalare precocemente un deterioramento funzionale o confermare un miglioramento.

**Dispositivi consumer.** Le feature più informative (frequenza dominante, jerk medio, SMA) sono calcolabili da qualsiasi accelerometro triassiale, inclusi quelli integrati in smartwatch e smartphone consumer. Questo abbatte la barriera economica all'accesso al monitoraggio cardiaco-riabilitativo.

**Supporto al terapista.** Un sistema automatico di riconoscimento dell'attività (OBJ1,  $F1 = 0,782$ ) può liberare il terapista dalla necessità di annotare manualmente le sessioni, consentendo una raccolta dati a lungo termine senza onere aggiuntivo.

**Soglia di allarme.** La distinzione REST vs ACTIVITY con accuratezza  $>95\%$  consente di filtrare automaticamente le finestre di riposo prima di calcolare i parametri HRV di base, garantendo che le misure cliniche siano estratte su dati fisiologicamente significativi.

## 6.3 Limiti del Lavoro

Nonostante i risultati incoraggianti, alcune limitazioni devono essere evidenziate per una corretta interpretazione:

**Numero di pazienti.** Il dataset copre decine di pazienti unici. Per OBJ3, dove la granularità effettiva è il paziente (non la finestra), questa dimensione è insufficiente per stime stabili delle prestazioni di generalizzazione. L'intervallo di confidenza dell' $F1$  su LOOCV è ampio.

**Assenza di validazione esterna.** Tutti i risultati sono interni al dataset. La generalizzabilità a pazienti acquisiti in un diverso ospedale, con dispositivi diversi o a frequenze di campionamento diverse, rimane da verificare.

**Etichetta NYHA soggettiva.** La classe NYHA è intrinsecamente soggettiva e dipende dall'autovalutazione del paziente. Questa soggettività introduce rumore nelle etichette di training che nessun algoritmo può eliminare completamente.

**Singola derivazione ECG.** La morfologia del QRS, il sottoslivellamento ST e la presenza di onde P anomale — tutti indicatori rilevanti per la valutazione cardiaca — non sono accessibili con una derivazione monoderivazione. L'aggiunta di derivazioni multiple migliorerebbe la ricchezza informativa del segnale ECG.

**Feature di interazione ACC-ECG.** La pipeline attuale concatena feature ACC e HRV in un unico vettore ma non esplora feature di *interazione* tra i due domini (es. coerenza tra risposta cardiaca e carico motorio). Questo tipo di feature potrebbe catturare relazioni più sottili.

## 6.4 Sviluppi Futuri

Le limitazioni sopra delineate suggeriscono le seguenti direzioni di sviluppo:

**Ampliamento del dataset.** L'arruolamento di un maggior numero di pazienti — in particolare nelle classi NYHA III e IV — è la priorità per rendere OBJ3 clinicamente affidabile. Idealmente, la raccolta dati multi-centro con protocollo standardizzato consentirebbe anche la validazione esterna.

**Classificazione morfologica ECG.** L'implementazione di un modulo di rilevazione automatica di anomalie ECG (extrasistoli ventricolari PVC, blocco di branca, sottoslivellamento ST da ischemia) tramite template matching o CNN 1D aggiungerebbe un layer diagnostico clinicamente prezioso. Questo costituisce il cosiddetto *Scenario C* della pipeline, attualmente non implementato.

**Deep learning sul segnale grezzo.** Approcci basati su reti neurali convoluzionali 1D (CNN) o reti ricorrenti (LSTM) applicati direttamente ai segnali ECG e ACC grezzi, senza estrazione manuale di feature, potrebbero migliorare le prestazioni su OBJ1 e OBJ3 apprendendo rappresentazioni ottimali in modo automatico. La letteratura recente mostra risultati promettenti su task analoghi [4].

**Feature di coerenza ACC-ECG.** Calcolare la coerenza spettrale (o la mutua informazione) tra il segnale ACC e la serie R-R potrebbe fornire una misura diretta dell'accoppiamento meccanocardiorespiratorio, più informativa delle correlazioni lineari singole analizzate in questo lavoro.

**Integrazione in un sistema di telemedicina.** La pipeline potrebbe essere integrata in un'architettura IoT con trasmissione remota dei dati: il dispositivo wearable

acquisisce ACC ed ECG, calcola le feature in locale (edge computing), e trasmette un vettore compresso a un server che restituisce la stima della classe NYHA al medico curante. Questo scenario è tecnicamente fattibile con microcontrollori a basso consumo (ARM Cortex-M4) e reti LPWAN.

**Analisi longitudinale.** I dati attuali sono trasversali (ogni paziente è registrato in un singolo momento della riabilitazione). Un dataset longitudinale — con misurazioni ripetute a intervalli regolari durante il percorso riabilitativo — consentirebbe di verificare se il modello rileva il miglioramento funzionale nel tempo, aprendo la strada al monitoraggio del *trajectories* cliniche individuali.

**Explainability (XAI).** L'adozione di tecniche di intelligenza artificiale spiegabile (SHAP — SHapley Additive exPlanations — e LIME — Local Interpretable Model-agnostic Explanations) per interpretare le previsioni del Random Forest su singoli pazienti potrebbe aumentare la fiducia dei clinici nel sistema, fornendo per ogni predizione una spiegazione in linguaggio clinico («la frequenza cardiaca elevata durante il cammino ha contribuito alla stima NYHA III»).

## 6.5 Validazione della Pipeline su una Seconda Coorte: Dataset SCG-RHC

A completamento del lavoro, la pipeline sviluppata è stata applicata a un secondo dataset indipendente, con l'obiettivo di verificarne la generalizzabilità a un contesto clinico differente. Il dataset SCG-RHC (*Seismocardiogram and Right Heart Catheter Database*, PhysioNet) raccoglie registrazioni di 83 pazienti con insufficienza cardiaca (HFrEF, HFpEF, trapianto cardiaco OHT, dispositivo VAD — Ventricular Assist Device) durante procedura di cateterismo cardiaco destro (RHC) in condizioni di riposo [19]. Ogni record comprende un patch wearable posizionato sul torace che acquisisce simultaneamente un canale ECG e tre canali accelerometrici (laterale, testa-piedi, dorso-ventrale) a 500 Hz per una durata di circa 10 minuti, affiancati da misure emodinamiche invasive quali pressione arteriosa polmonare (PAM), pressione di incuneamento capillare polmonare (PCWM) e gittata cardiaca (CO).

### 6.5.1 Obiettivo e Protocollo Sperimentale

L'obiettivo dell'esperimento è verificare se le stesse feature HRV e accelerometriche estratte nel dataset principale siano in grado di distinguere pazienti in stato emodinamico *compensato* ( $PCWM < 20$  mmHg e/o indice cardiaco  $> 2,2$  L/min/m<sup>2</sup>) da pazienti in stato *scompensato* ( $PCWM \geq 20$  mmHg e indice cardiaco  $\leq 2,2$  L/min/m<sup>2</sup>), utilizzando il campo `CDecomp` del metadato JSON come etichetta di ground truth.

Il protocollo applicato è identico a quello del dataset principale: preprocessing del segnale ECG con filtraggio passa-banda e rilevamento R-peaks Pan-Tompkins, prepro-

cessing accelerometrico con rimozione della componente gravitazionale, estrazione delle medesime 72 feature HRV e ACC, filtraggio SQI e classificazione con Random Forest, SVM e Logistic Regression. L'unica differenza tecnica è la frequenza di campionamento, pari a 500 Hz per entrambe le modalità — compatibile con le funzioni `preprocess_ecg(fs=500)` e `preprocess_acc(fs=500)` già implementate. La cross-validazione è condotta con *StratifiedGroupKFold* per prevenire il data leakage inter-paziente (OBJ\_DS2a), e con aggregazione per paziente e *Leave-One-Out Cross-Validation* (LOOCV) come gold standard (OBJ\_DS2b).

### 6.5.2 Risultati

Il dataset elaborato comprende **8.192 finestre valide** estratte da **82 record** (un record privo di canale ECG è stato escluso), con una distribuzione delle etichette di 4.875 finestre compensate (59,5 %) e 3.317 scompenso (40,5 %).

| Variante                 | Modello             | F1 pesato    | Note                 |
|--------------------------|---------------------|--------------|----------------------|
| OBJ_DS2a — window-level  | Random Forest       | 0,635        | StratifiedGroupKFold |
| OBJ_DS2a — window-level  | SVM                 | <b>0,647</b> | StratifiedGroupKFold |
| OBJ_DS2a — window-level  | Logistic Regression | 0,636        | StratifiedGroupKFold |
| OBJ_DS2b — patient-level | Random Forest       | <b>0,625</b> | LOOCV — 82 pazienti  |
| OBJ_DS2b — patient-level | Logistic Regression | 0,591        | LOOCV — 82 pazienti  |

**Tabella 6.1:** Risultati classificazione CDecomp (Compensato vs Scompensato) sul dataset SCG-RHC.

### 6.5.3 Discussione

I risultati in Tabella 6.1 mostrano che la pipeline, addestrata e progettata interamente sul dataset di riabilitazione post-chirurgica (DS), produce prestazioni significativamente superiori al caso ( $F1 = 0.647$  vs  $F1_{\text{caso}} \approx 0.50$  su task bilanciato) quando applicata *senza modifiche* a una coorte di pazienti con insufficienza cardiaca in un contesto clinico completamente diverso.

Emergono due osservazioni di rilievo. In primo luogo, la coerenza tra la variante a livello finestra ( $F1 = 0,635\text{--}0,647$ ) e la variante a livello paziente con LOOCV ( $F1 = 0,625$ ) indica che le prestazioni non sono artificio della struttura a finestre sovrapposte, ma riflettono un segnale genuino nei dati. In secondo luogo, il modello SVM supera il Random Forest su questo dataset — un'inversione rispetto ai risultati del dataset prin-



cipale — riconducibile all’omogeneità della coorte (tutti i pazienti sono a riposo, stessa postura, frequenza di campionamento uniforme), che rende la frontiera di decisione più regolare e quindi più adatta a un classificatore a margine massimo.

Sul piano clinico, il risultato dimostra che le feature HRV e SCG estratte da un wearable patch non invasivo contengono informazione sullo stato emodinamico del paziente, aprendo la prospettiva di uno *screening* non invasivo dello scompenso cardiaco basato su segnali facilmente acquisibili in ambiente ambulatoriale o domiciliare. Questo risultato, pur preliminare, è coerente con la letteratura emergente sul seismocardiogramma come marcatore di funzione cardiaca meccanica [20].

È importante sottolineare che questo studio di generalizzabilità ha natura *esplorativa*: le popolazioni dei due dataset sono diverse (post-cardiochirurgici in attività vs pazienti con HF a riposo), i contesti clinici non sono comparabili e le ipotesi di lavoro sono distinte. I risultati non sono pertanto direttamente confrontabili con quelli del dataset principale, ma costituiscono un’evidenza complementare della robustezza e riutilizzabilità della pipeline proposta.

## 6.6 Osservazioni Conclusive

Il lavoro presentato in questa tesi dimostra la fattibilità di un sistema di monitoraggio cardiaco e motorio basato interamente su segnali wearable, senza sensori invasivi o attrezzature cliniche specializzate. I tre obiettivi di classificazione — tipo di attività motoria, distinzione riposo/attività e stima della classe NYHA — sono stati raggiunti con una pipeline unica e coerente, validata su un dataset reale di pazienti post-cardiochirurgici e generalizzata a una seconda coorte indipendente con insufficienza cardiaca.

Il risultato più rilevante è che feature semplici, calcolabili in tempo reale su microcontrollori a basso consumo, contengono informazione clinicamente significativa sullo stato cardiaco e funzionale del paziente. La correlazione tra segnale accelerometrico e parametri HRV — pur moderata nella sua componente lineare — risulta sufficiente a supportare classificatori che superano il caso in tutti e tre gli obiettivi, con il Random Forest che si afferma come modello più adatto alla natura eterogenea e non lineare del dominio.

Questo lavoro si colloca come contributo preliminare alla transizione dal monitoraggio clinico *spot* al monitoraggio continuo e non invasivo nella riabilitazione cardiaca: una direzione indicata dalla letteratura emergente e resa tecnologicamente accessibile dall’evoluzione dei dispositivi indossabili consumer e dell’infrastruttura di edge computing.

## Appendice A — Frammenti di Codice

Questa appendice raccoglie i frammenti di codice più rappresentativi della pipeline sviluppata, a fini di riproducibilità e documentazione tecnica. Il codice sorgente completo è disponibile nel repository del progetto.

### Pre-elaborazione ECG e Rilevamento R-peaks

Il seguente estratto mostra il filtraggio Butterworth zero-phase e il rilevamento dei picchi R tramite NeuroKit2.

```
import numpy as np
from scipy.signal import butter, sosfiltfilt
import neurokit2 as nk

def preprocess_ecg(signal: np.ndarray, fs: int = 130) -> dict:
    """
    Pre-elabora il segnale ECG grezzo e restituisce gli intervalli RR puliti.
    fs: frequenza di campionamento in Hz (130 Hz per il dataset principale,
        500 Hz per il dataset SCG-RHC).
    """
    # Filtro passa-banda Butterworth 4° ordine, zero-phase (sosfiltfilt evita
    # sfasamento), banda 0.5-40 Hz: taglia il baseline wander e il rumore
    muscolare
    sos = butter(4, [0.5, 40.0], btype="bandpass", fs=fs, output="sos")
    ecg_filt = sosfiltfilt(sos, signal)

    # Rilevamento picchi R con algoritmo Pan-Tompkins implementato da
    NeuroKit2.
    # Il metodo restituisce i sample index dei picchi R nel segnale filtrato.
    _, info = nk.ecg_peaks(ecg_filt, sampling_rate=fs,
                           method="pantompkins1985")
    r_peaks = info["ECG_R_Peaks"]

    # Calcolo intervalli RR in millisecondi come differenza tra campioni
    consecutivi.
    # Si applica un filtraggio fisiologico: si scartano intervalli < 300 ms
    # (FC > 200 bpm, quasi certamente artefatti) e > 2000 ms (FC < 30 bpm).
    rr_ms = np.diff(r_peaks) / fs * 1000.0
    rr_clean = rr_ms[(rr_ms >= 300) & (rr_ms <= 2000)]
    return {"rr_ms": rr_clean, "r_peaks": r_peaks}
```

## Signal Quality Index (SQI)

La funzione seguente implementa il filtro di qualità multi-criterio applicato a ogni finestra prima dell'estrazione delle feature.

```
def compute_sqi(ecg_win, acc_win, fs_ecg=130):
    """
    Calcola il Signal Quality Index per una finestra temporale di 30 s.
    Restituisce True solo se ECG e ACC superano contemporaneamente tutti i
    criteri.
    Una singola finestra non valida viene scartata: meglio perdere dati che
    addestrare i modelli su segnali corrotti.
    """
    # --- Criteri di qualità ECG ---
    # Flatline: frazione di campioni con variazione nulla → distacco elettrodo
    flatline = np.mean(np.diff(ecg_win) == 0)
    # Clipping: campioni che toccano i limiti di saturazione dell'ADC
    clip_hi = np.mean(ecg_win >= 0.99 * ecg_win.max())
    clip_lo = np.mean(ecg_win <= 1.01 * ecg_win.min())
    # Calcolo intervalli RR e coefficiente di variazione come indicatore di
    qualità
    rr = preprocess_ecg(ecg_win, fs=fs_ecg)["rr_ms"]
    n_rr = len(rr)
    # CV_RR > 40% indica variabilità anomala, probabilmente artefatti da
    movimento
    cv_rr = rr.std() / rr.mean() * 100 if len(rr) > 0 else 999
    ecg_ok = (flatline < 0.05 and clip_hi + clip_lo < 0.02
              and n_rr >= 5 and cv_rr < 40.0)

    # --- Criteri di qualità ACC (calcolati sulla magnitudine vettoriale) ---
    # La magnitudine è invariante rispetto all'orientamento del sensore
    mag = np.sqrt((acc_win**2).sum(axis=1))
    # Flatline ACC: sensore fermo o disconnesso; range < 5 mg: segnale troppo
    silenzioso;
    # std > 10 g: artefatto impulsivo di grande ampiezza (urto, caduta del
    dispositivo)
    acc_ok = (np.mean(np.diff(mag) == 0) < 0.10
              and mag.max() - mag.min() > 0.005 # > 5 mg di dinamica minima
              and mag.std() < 10.0)
    # La finestra è valida solo se entrambi i segnali sono accettabili
    return ecg_ok and acc_ok
```

## Estrazione Feature HRV

L'estratto seguente mostra il calcolo delle principali feature nel dominio del tempo e della frequenza a partire dalla serie RR.

```

def extract_hrv_features(rr_ms: np.ndarray) -> dict:
    """
    Calcola le feature HRV nel dominio del tempo e gli indici di Poincaré
    a partire dalla serie di intervalli RR (in millisecondi).
    Richiede almeno 5 intervalli validi; in caso contrario restituisce
    un dizionario vuoto che verrà poi imputato con la mediana della colonna.
    """

    if len(rr_ms) < 5:
        return {} # finestra troppo corta: non affidabile

    feats = {
        # Indici statistici di base: media e deviazione standard degli RR
        "mean_rr" : np.mean(rr_ms),
        # SDNN: variabilità globale, include contributi sia simpatici che
vagli
        "sdnn"     : np.std(rr_ms, ddof=1),
        # RMSSD: sensibile all'attività parasimpatica (vagale) ad alta
frequenza
        "rmssd"    : np.sqrt(np.mean(np.diff(rr_ms)**2)),
        # pNN50 e pNN20: percentuale di differenze successive sopra soglia
        "pnn50"    : np.mean(np.abs(np.diff(rr_ms)) > 50) * 100,
        "pnn20"    : np.mean(np.abs(np.diff(rr_ms)) > 20) * 100,
    }
    # Frequenza cardiaca media (bpm) e coefficiente di variazione
    feats["hr_mean"] = 60_000 / feats["mean_rr"]
    feats["cv_rr"]   = feats["sdnn"] / feats["mean_rr"] * 100

    # Indici di Poincaré: SD1 cattura la variabilità battito-per-battito
(vagale),
    # SD2 la variabilità a lungo termine (simpatico-vagale)
    feats["sd1"] = np.sqrt(0.5) * feats["rmssd"]
    feats["sd2"] = np.sqrt(
        max(2 * feats["sdnn"]**2 - 0.5 * feats["rmssd"]**2, 0))
    # Il rapporto SD1/SD2 scende in stati di stress autonomico
    feats["sd1_sd2_ratio"] = (feats["sd1"] / feats["sd2"]
                             if feats["sd2"] > 0 else np.nan)

    return feats

```

## Pipeline di Classificazione con GroupKFold

L'estratto seguente illustra la costruzione della pipeline scikit-learn con validazione a livello paziente per prevenire il data leakage su OBJ3.

```

from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestClassifier

```

```

from sklearn.model_selection import (StratifiedGroupKFold,
                                     cross_val_predict)
from sklearn.metrics import f1_score

# La pipeline incapsula in sequenza: imputazione dei NaN con la mediana
# (alcuni pazienti hanno feature mancanti per finestre brevi),
# standardizzazione
# Z-score e classificatore. Questo garantisce che scaling e imputazione
# vengano
# applicati solo sui dati di training di ciascun fold, evitando data leakage.
pipe = Pipeline([
    ("imputer", SimpleImputer(strategy="median")), # robusto agli outlier
    ("scaler", StandardScaler()),                # normalizzazione Z-score
    ("clf", RandomForestClassifier(
        n_estimators=200,
        class_weight="balanced", # compensa lo sbilanciamento
        n_jobs=-1,               # parallelizzazione su tutti i
        random_state=42)),       # riproducibilità
    ])

# StratifiedGroupKFold garantisce che:
# 1) le proporzioni delle classi siano bilanciate in ogni fold (Stratified)
# 2) le finestre dello stesso paziente non compaiano mai in fold diversi
# (Group)
# → nessun paziente è contemporaneamente nel training e nel test set
cv = StratifiedGroupKFold(n_splits=3)
y_pred = cross_val_predict(pipe, X, y, cv=cv, groups=patient_ids)

# F1 pesato: media ponderata per il supporto di classe, robusta allo
# sbilanciamento
print(f"F1 weighted: {f1_score(y, y_pred, average='weighted'):.3f}")

```

## Bibliografia

- [1] World Health Organization, «Cardiovascular diseases (CVDs)», 2021.
- [2] L. Anderson *et al.*, «Exercise-based cardiac rehabilitation for coronary heart disease», *Cochrane Database of Systematic Reviews*, fasc. 1, 2016, doi: 10.1002/14651858.CD001800.pub3.
- [3] The Criteria Committee of the New York Heart Association, «Nomenclature and Criteria for Diagnosis of Diseases of the Heart and Great Vessels». Little, Brown & Co., Boston, MA, 1994.
- [4] A. Pantelopoulos e N. G. Bourbakis, «A survey on wearable sensor-based systems for health monitoring and prognosis», *IEEE Transactions on Systems, Man, and Cybernetics, Part C*, vol. 40, fasc. 1, pp. 1–12, 2010, doi: 10.1109/TSMCC.2009.2032660.
- [5] Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, «Heart rate variability: Standards of measurement, physiological interpretation, and clinical use», *Circulation*, vol. 93, fasc. 5, pp. 1043–1065, 1996, doi: 10.1161/01.CIR.93.5.1043.
- [6] S. M. Pincus, «Approximate entropy as a measure of system complexity», *Proceedings of the National Academy of Sciences*, vol. 88, fasc. 6, pp. 2297–2301, 1991, doi: 10.1073/pnas.88.6.2297.
- [7] J. S. Richman e J. R. Moorman, «Physiological time-series analysis using approximate entropy and sample entropy», *American Journal of Physiology — Heart and Circulatory Physiology*, vol. 278, fasc. 6, pp. H2039–H2049, 2000, doi: 10.1152/ajpheart.2000.278.6.H2039.
- [8] C.-K. Peng, S. Havlin, H. E. Stanley, e A. L. Goldberger, «Quantification of scaling exponents and crossover phenomena in nonstationary heartbeat time series», *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 5, fasc. 1, pp. 82–87, 1995, doi: 10.1063/1.166141.
- [9] J. Pan e W. J. Tompkins, «A real-time QRS detection algorithm», *IEEE Transactions on Biomedical Engineering*, vol. 32, fasc. 3, pp. 230–236, 1985, doi: 10.1109/TBME.1985.325532.
- [10] D. Makowski *et al.*, «NeuroKit2: A Python toolbox for neurophysiological signal processing», *Behavior Research Methods*, vol. 53, pp. 1689–1696, 2021, doi: 10.3758/s13428-020-01516-y.
- [11] N. R. Lomb, «Least-squares frequency analysis of unequally spaced data», *Astrophysics and Space Science*, vol. 39, pp. 447–462, 1976, doi: 10.1007/BF00648343.

- [12] L. Breiman, «Random forests», *Machine Learning*, vol. 45, fasc. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.
- [13] C. Cortes e V. Vapnik, «Support-vector networks», *Machine Learning*, vol. 20, fasc. 3, pp. 273–297, 1995, doi: 10.1007/BF00994018.
- [14] N. V. Chawla, K. W. Bowyer, L. O. Hall, e W. P. Kegelmeyer, «SMOTE: Synthetic minority over-sampling technique», *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002, doi: 10.1613/jair.953.
- [15] F. Pedregosa *et al.*, «Scikit-learn: Machine learning in Python», *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [16] C. R. Harris, K. J. Millman, S. J. van der Walt, e others, «Array programming with NumPy», *Nature*, vol. 585, pp. 357–362, 2020, doi: 10.1038/s41586-020-2649-2.
- [17] The Pandas Development Team, «pandas-dev/pandas: Pandas». Zenodo, 2020. doi: 10.5281/zenodo.3509134.
- [18] P. Virtanen, R. Gommers, T. E. Oliphant, e others, «SciPy 1.0: Fundamental algorithms for scientific computing in Python», *Nature Methods*, vol. 17, pp. 261–272, 2020, doi: 10.1038/s41592-019-0686-2.
- [19] A. Taebi e H. A. Mansy, «SCG-RHC Wearable Dataset: Simultaneous Seismocardiogram and Right Heart Catheter Recordings in Heart Failure Patients». PhysioNet, 2023. doi: 10.13026/s1am-fh83.
- [20] A. Taebi, B. E. Solar, A. J. Bomar, R. H. Sandler, e H. A. Mansy, «Recent advances in seismocardiography», *Vibration*, vol. 2, fasc. 1, pp. 64–86, 2019, doi: 10.3390/vibration2010005.